

```
In [1]: # %matplotlib notebook
%matplotlib inline
```

# 机器学习入门实验

## 课程目标

1. 熟悉机器学习开发环境
2. 查阅常用数据集说明
3. 学习数据读写方法以及数据可视化方法

## 数据集

本次实验我们将认识鸢尾花卉数据集（Iris flower dataset），糖尿病数据集（Diabetes dataset），以及西瓜数据集2.0/3.0。

### 鸢尾花卉数据集（Iris flower dataset）

其数据集包含了150个样本，都属于鸢尾属下的3个亚属，分别是山鸢尾（学名：Iris setosa）、变色鸢尾（学名：Iris versicolor）和维吉尼亚鸢尾。每个样本都包含4项特征，即花萼和花瓣的长度和宽度，它们可用于样本的定量分析。

山鸢尾（学名：Iris setosa）



变色鸢尾（学名：Iris versicolor）



维吉尼亚鸢尾（学名：Iris virginica）



scikit-learn附带了一些小型的标准数据集（包括Iris），不需要从外部网站下载任何文件。

```
In [2]: # 导入所需的库
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn import datasets
```

```

# 加载iris数据集
iris = datasets.load_iris()
X = iris.data # 特征矩阵
y = iris.target # 标签向量
feature_names = iris.feature_names # 特征名称
target_names = iris.target_names # 标签名称

# 将数据转换为DataFrame格式, 方便查看和操作
df = pd.DataFrame(X, columns=feature_names)
df['target'] = y
df['target_name'] = df['target'].apply(lambda x: target_names[x])

# 查看数据集的基本信息
print(df.head())
print(df.describe())
print(df['target_name'].value_counts())

```

|   | sepal length (cm) | sepal width (cm) | petal length (cm) | petal width (cm) | \ |
|---|-------------------|------------------|-------------------|------------------|---|
| 0 | 5.1               | 3.5              | 1.4               | 0.2              |   |
| 1 | 4.9               | 3.0              | 1.4               | 0.2              |   |
| 2 | 4.7               | 3.2              | 1.3               | 0.2              |   |
| 3 | 4.6               | 3.1              | 1.5               | 0.2              |   |
| 4 | 5.0               | 3.6              | 1.4               | 0.2              |   |

|   | target | target_name |
|---|--------|-------------|
| 0 | 0      | setosa      |
| 1 | 0      | setosa      |
| 2 | 0      | setosa      |
| 3 | 0      | setosa      |
| 4 | 0      | setosa      |

|       | sepal length (cm) | sepal width (cm) | petal length (cm) | \ |
|-------|-------------------|------------------|-------------------|---|
| count | 150.000000        | 150.000000       | 150.000000        |   |
| mean  | 5.843333          | 3.057333         | 3.758000          |   |
| std   | 0.828066          | 0.435866         | 1.765298          |   |
| min   | 4.300000          | 2.000000         | 1.000000          |   |
| 25%   | 5.100000          | 2.800000         | 1.600000          |   |
| 50%   | 5.800000          | 3.000000         | 4.350000          |   |
| 75%   | 6.400000          | 3.300000         | 5.100000          |   |
| max   | 7.900000          | 4.400000         | 6.900000          |   |

|            | petal width (cm) | target     |
|------------|------------------|------------|
| count      | 150.000000       | 150.000000 |
| mean       | 1.199333         | 1.000000   |
| std        | 0.762238         | 0.819232   |
| min        | 0.100000         | 0.000000   |
| 25%        | 0.300000         | 0.000000   |
| 50%        | 1.300000         | 1.000000   |
| 75%        | 1.800000         | 2.000000   |
| max        | 2.500000         | 2.000000   |
| setosa     | 50               |            |
| versicolor | 50               |            |
| virginica  | 50               |            |

Name: target\_name, dtype: int64

In [3]: # 绘制两两特征之间的散点图, 用不同颜色区分不同类别的花

```

plt.figure(figsize=(12, 12))
for i in range(4):
    for j in range(4):
        plt.subplot(4, 4, i * 4 + j + 1)


```

```

if i == j:
    plt.hist(df[feature_names[i]], color='gray')
    plt.xlabel(feature_names[i])
else:
    plt.scatter(df[feature_names[j]], df[feature_names[i]], c=df['target'], cn
    plt.xlabel(feature_names[j])
    plt.ylabel(feature_names[i])
plt.suptitle('Pairwise scatter plot of iris features')
plt.show()

```

Pairwise scatter plot of iris features




```

In [4]: # 绘制三维散点图, 选择三个特征进行可视化
from mpl_toolkits.mplot3d import Axes3D
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
ax.scatter(df['sepal length (cm)'], df['sepal width (cm)'], df['petal length (cm)'], c=
ax.set_xlabel('sepal length (cm)')
ax.set_ylabel('sepal width (cm)')

```

```
ax.set_zlabel('petal length (cm)')
ax.set_title('3D scatter plot of iris features')
plt.show()
```

3D scatter plot of iris features



## 糖尿病数据集 (Diabetes dataset)

Diabetes dataset是一个用于回归分析的数据集，它包含了442个样本和10个特征。这些特征是年龄、性别、体重指数、平均血压和6个血清测量。目标变量是一年后疾病进展的定量指标 (progression)。这个数据集是从Framingham心脏研究中的442名糖尿病患者中提取的。

```
In [5]: # 导入所需的库
import numpy as np
import matplotlib.pyplot as plt
from sklearn import datasets


# 加载 diabetes dataset
diabetes = datasets.load_diabetes()

# 获取特征和标签
X = diabetes.data
y = diabetes.target

# 绘制训练集中每个特征与标签的散点图
plt.figure(figsize=(15, 10))
for i in range(10):
    plt.subplot(2, 5, i+1)
    plt.scatter(X[:, i], y)
    plt.xlabel(diabetes.feature_names[i])
    plt.ylabel('target')
```

```
plt.suptitle('Scatter plots of features and target in diabetes dataset')
plt.show()
```

Scatter plots of features and target in diabetes dataset



## 上机内容

1. 安装和配置机器学习开发环境，包括Python、Jupyter Notebook、Numpy、Pandas、Matplotlib。
2. 熟悉Jupyter Notebook、Numpy、Pandas、Matplotlib的使用方法。
3. 结合上述示例代码的加载数据方法，针对鸢尾花数据集（Iris）和糖尿病数据集（Diabetes dataset），查阅其说明文档，了解其特征和标签的含义。
4. 结合上述示例代码的可视化方法，了解如何使用Pandas和Matplotlib进行基本的数据处理与可视化，如查看数据维度、数据类型、统计信息等，观察数据的分布和相关性。
5. （选做）根据可视化结果与课上所教授内容，选择合适的模型和算法进行尝试。
6. 根据教材内容，编写python代码，生成西瓜数据集2.0和3.0，并尝试保存和读取生成的数据集。
7. 使用Matplotlib对西瓜数据集3.0进行可视化分析，观察数据的分布和相关性。
8. 编写报告，总结上机内容的过程和结果，并给出自己的感想和建议。