
第二章：模型评估 与选择

大纲

- 经验误差与过拟合

- 评估方法

- 性能度量

- 偏差与方差

经验误差与过拟合

❑ 错误率

分类错误的样本在样本总数中的比例： $E = a/m$

错分样本数目
样本总数

❑ 精度

分类正确的样本在样本总数中的占比： $Acc = 1 - a/m$



➤ 样本总数 $m = 10$ ➤ 错分样本数 $a = 3$

➤ 错误率 $E = 0.3$

➤ 精度 $Acc = 0.7$

经验误差与过拟合

□ 误差

学习器**预测输出**与样本的**真实输出**之间的差异

➤ 训练误差 / 经验误差

学习器在**训练数据集**上的误差

➤ 泛化误差

学习器在**新样本数据**上的误差



新样本数据往往是**未知**的

学习器的训练方向：降低经验误差

但经验误差也并非越低越好



经验误差与过拟合

□ 过拟合

学习器将训练样本学习的“太好”，将训练样本的自身特点当做所有样本的一般性质，导致泛化性能下降


□ 欠拟合

对训练样本的一般性质尚未学好



经验误差与过拟合

树叶训练样本



新样本



过拟合模型分类结果：
→ 不是树叶
(误以为树叶必须有锯齿)

欠拟合模型分类结果：
→ 是树叶
(误以为绿色的都是树叶)

一个过拟合、欠拟合的直观类比

欠拟合

□ 欠拟合 (underfitting) :

- 模型无法拟合训练数据，表现为模型的预测能力较差。这通常发生在模型过于简单或者数据特征复杂时。如：线性模型拟合非线性数据。
- 欠拟合的原因在于：
 - ①特征量过少；
 - ②模型复杂度过低；

过拟合 (overfitting)

- 模型过度拟合了训练数据，表现为模型在训练数据上表现很好，但在测试数据上表现很差。
- 学习器把训练样本学习的“太好”，将训练样本本身的特性当做所有样本的共性，导致泛化性能下降。
- 过拟合的主要原因有：
 1. 参数太多，模型复杂度过高；
 2. 建模样本选取有误，导致选取的样本数据不足以代表预定的分类规则；
 3. 样本噪音干扰过大，使得机器将部分噪音认为是特征从而扰乱了预设的分类规则；
 4. 假设的模型无法合理存在，或者说是假设成立的条件实际并不成立。

大纲

- 经验误差与过拟合

- 评估方法

- 性能度量

- 偏差与方差

评估方法

现实任务中面临多种学习算法可供选择



同一学习算法，不同参数配置也会产生不同的模型



新样本未知，无法直接计算泛化误差




如何实现对模型的选择与评估？？？

经验误差与过拟合

□ 实验测试

包含所有样本的数据集 $D = \{(x_1, y_1); \dots; (x_m, y_m)\}$



将包含个 m 个样本的数据集拆分成训练集 S 和测试集 T ;

通过测试误差近似泛化误差，从而判断学习器对新样本的判别能力


- 测试数据集: 从样本真实分布中独立同分布采样而来
- 测试集与训练集应当尽可能互斥

经验误差与过拟合

□ 留出法

直接将数据集划分为两个互斥集合，在训练集上训练出模型后，用测试集评估其测试误差，并作为对泛化误差的估计。

- 训练/测试集划分要尽可能保持**数据分布的一致性**
- 单次使用留出法的估计结果不够稳定可靠，实际面对新样本，一般采用**若干次**随机划分、重复实验取平均值




- 训练/测试样本比例通常为**2:1~4:1**

评估方法

交叉验证法

将数据集分层采样划分为 k 个大小相似的互斥子集，每次用 $k-1$ 个子集的并集作为训练集，余下的子集作为验证集，最终返回 k 个测试结果的均值， k 最常用的取值是10



评估方法

- 多次随机划分

与留出法类似，为了减小因样本划分不同而引入的差别， k 折交叉验证会随机采用不同的划分方式重复 p 次，最终的评估结果是这 p 次 k 折交叉验证结果的均值，例如常见的“10次10折交叉验证”

- 留一法

包含 m 个样本的数据集 D ，令 k 折交叉验证中的参数 $k = m$

- 不受随机样本划分方式的影响
- 结果往往比较准确
- 当数据集比较大时，计算开销难以忍受

评估方法

□ 自助法

对数据集 D 有放回采样 m 次取得训练集 D' ，未被采样到的样本 $D \setminus D'$ 做测试集。

- 实际模型与预期模型都使用 m 个训练样本
- 约有1/3的样本没在训练集中出现，可作为测试集

$$\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \approx 0.368$$

- 自助法在数据集较小、难以有效划分训练/测试集时很有用
- 由于改变了数据集分布可能引入估计偏差，在数据量足够时，留出法和交叉验证法更为常用

评估方法小结

□ 留出法：

- 一般若干次随机划分、重复实验取平均值
- 训练/测试样本比例通常为2:1~4:1

□ 交叉验证法：

- 将数据集分层采样划分为 k 个大小相似的互斥子集，每次用 $k-1$ 个子集的并集作为训练集，余下的子集作为测试集，最终返回 k 个测试结果的均值。
- 一般会重复 p 次，最终的评估结果是 p 次 k 折交叉验证结果的均值。
- 留一法：当 $k=m$ 时的特例（ m 为样本的数量）

□ 自助法：

- 以自助采样法为基础，对数据集 D 有放回采样 m 次得到训练集 D' ， $D \setminus D'$ 用做测试集。
- 实际模型与预期模型都使用 m 个训练样本。

大纲

- 经验误差与过拟合
- 评估方法
- 性能度量
- 偏差与方差

性能度量

□ 性能度量

衡量模型泛化能力的评价标准

- 一般是将学习器的预测结果与真实标记进行比较
- 不同的性能度量往往会导致不同的评判结果，即模型的好坏是相对的，取决于任务需求

性能度量

❑ 错误率与精度的数学表达

给定数据集 $D = \{(\mathbf{x}_1, y_1); \dots; (\mathbf{x}_m, y_m)\}$

- y_i : 第 i 个样本 $\mathbf{x}_i$ 的**真实标记**
- $f(\mathbf{x}_i)$: 学习器模型对数据 $\mathbf{x}_i$ 的**预测结果**

❑ 错误率

分类**错误**的样本在样本总数中的比例

离散任务（分类）

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) \neq y_i)$$

$\mathbb{I}(\cdot)$: 示性函数

连续任务（回归）

$p(\cdot)$: 概率密度函数

$$E(f; D) = \int_{\mathbf{x} \sim \mathcal{D}} \mathbb{I}(f(\mathbf{x}) \neq y) p(\mathbf{x}) d\mathbf{x}$$

$\mathcal{D}$: 数据分布

性能度量

□ 错误率与精度的数学表达

给定数据集 $D = \{(\mathbf{x}_1, y_1); \dots; (\mathbf{x}_m, y_m)\}$

- y_i : 第 i 个样本 $\mathbf{x}_i$ 的**真实标记**
- $f(\mathbf{x}_i)$: 学习器模型对数据 $\mathbf{x}_i$ 的**预测结果**

□ 精度

分类**正确**的样本在样本总数中的比例

离散任务（分类）	连续任务（回归）
$\begin{aligned}\text{acc}(f; D) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) = y_i) \\ &= 1 - E(f; D)\end{aligned}$	$\begin{aligned}\text{acc}(f; D) &= \int_{\mathbf{x} \sim D} \mathbb{I}(f(\mathbf{x}) = y) p(\mathbf{x}) d\mathbf{x} \\ &= 1 - E(f; D)\end{aligned}$

性能度量

□ 查准率&查全率

错误率与精度虽然能评估预测是否准确，但无法满足全部的任务需求

➤ 以信息检索为例：

- 检索出的信息有多少比例示用户有兴趣的？
- 用户感兴趣的信息有多少比例被检索出来？

此时查准率和查全率比错误率和精度更适合

分类结果混淆矩阵

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

$$\text{查准率 } P = \frac{TP}{TP+FP}$$

$$\text{查全率 } R = \frac{TP}{TP+FN}$$

例子：混淆矩阵、查准率&查全率

假设我们有一个二分类问题，目标是预测一封电子邮件是否是垃圾邮件（正类）还是不是垃圾邮件（负类）。假设以下信息：

- 测试集大小：120
- 实际正类（垃圾邮件）实例：40；实际负类（非垃圾邮件）实例：80
- 模型预测：
预测为正类（垃圾邮件）：35； 预测为负类（非垃圾邮件）：85

在40个实际正类（垃圾邮件）实例中，模型预测为正类32个，预测为负类8个。在80个实际负类（非垃圾邮件）实例中，模型预测为正类3个，预测为负类77个。

根据上述数据写出对应的混淆矩阵，并计算准确率（Accuracy）、精确率（Precision）和召回率（Recall）

$$\text{查准率 } P = \frac{TP}{TP+FP}$$

$$\text{查全率 } R = \frac{TP}{TP+FN}$$

例子：混淆矩阵、查准率&查全率

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	32 (TP, 真正率)	8 (FN, 假反率)
反例	3 (FP, 假正率)	77 (TN, 真反率)

$$\text{准确率: Accuracy} = \frac{TP+TN}{P+FN+FP+TN} = \frac{32+77}{120} = \frac{109}{120} = 0.908$$

$$\text{查准率: } P = \frac{TP}{TP+FP} = \frac{32}{32+3} = \frac{32}{35} = 0.914$$

$$\text{查全率: } R = \frac{TP}{TP+FN} = \frac{32}{32+8} = \frac{32}{40} = 0.8$$

性能度量

□ 查准率&查全率

查准率和查全率之间**相互矛盾**：

➤ 以**信息检索**为例：

- 提高**查全率**（即提高用户感兴趣的信息的检索比例）



尽可能扩大检索的信息范围



无效的信息增多，**查准率**下降

性能度量

□ 查准率&查全率

查准率和查全率之间**相互矛盾**：

➤ 以**信息检索**为例：

- 提高**查准率**（即提高检索出的信息中用户感兴趣的比例）



如果只在有把握的范围内检索




查准率很高，但会遗漏很多相关信息，查全率较低

性能度量

□ P-R曲线


根据学习器的预测结果按正例可能性大小**对样本进行排序**，并逐个把样本作为正例进行预测，从而得到**查准率-查全率曲线**



性能度量

□ P-R曲线


根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，从而得到查准率-查全率曲线



性能度量

□ P-R曲线

根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，从而得到查准率-查全率曲线



性能度量

□ P-R曲线

根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，从而得到查准率-查全率曲线

真实情况




学习器预测
的好瓜概率

0.9 0.85 0.8 0.75 0.75 0.7 0.6 0.4 0.3 0.2

查准率 $P = 0.55$

查全率 $R = 1$

查准率




查全率

性能度量

□ P-R曲线

根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，从而得到查准率-查全率曲线



P-R曲线与平衡点示意图


□ 不同学习器P-R曲线比较

- 若一个学习器的P-R曲线能将另一个学习器完全**包住**，则前者性能优于后者。（B优于C）
- 若两个学习器的P-R曲线发生**交叉**，则可通过P-R曲线包围的面积进行判断。（但面积估算不易）

性能度量

● 平衡点

P-R曲线上“查准率=查全率”时的取值，平衡点越高，学习器性能越好（A优于B）



P-R曲线与平衡点示意图

性能度量

● $F1$ 度量

比平衡点更为常用的度量方式

$$F1 = \frac{2 \times P \times R}{P + R}$$

● F_β 度量

当对查全率、查准率有侧重点时使用的更为一般的度量方式

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

- 当 $\beta = 1$ 时，标准F1度量
- 当 $\beta < 1$ 时，偏重查准率(商品推荐系统)
- 当 $\beta > 1$ 时，偏重查全率(逃犯信息检索)

性能度量

□ ROC曲线 (ROC: Receiver Operating Characteristic)

与P-R曲线类似，根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测绘制出的坐标曲线，其中，横坐标为FPR(假正率)，纵坐标为TPR（真正率）。

分类结果混淆矩阵

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

➤ 真正率TPR（纵坐标）

$$TPR = \frac{TP}{TP + FN}$$

➤ 假正率FPR（横坐标）

$$FPR = \frac{FP}{FP + TN}$$

ROC曲线 (ROC: Receiver Operating Characteristic)

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

- 真正率TPR (纵坐标)

$$TPR = \frac{TP}{TP + FN} \longrightarrow \text{真实的正例总数量}$$

- 假正率FPR (横坐标)

$$FPR = \frac{FP}{TN + FP} \longrightarrow \text{真实的反例总数量}$$

FPR和TPR的分母是不变。

ROC曲线

样本序号	样本真实标记 (1 or 0)	为正例的概率
1	1	0.95
2	0	0.88
3	1	0.85
4	1	0.72
5	0	0.56

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{TN + FP}$$

第一回合：

以100%为阈值，则预测为正例的数量为0，预测为反例的数量为5。

真实情况	预测结果	
	正例	反例
正例	0 (TP)	3 (FN)
反例	0 (FP)	2 (TN)

$$TPR = 0, \quad FPR = 0$$

ROC曲线

样本序号	样本真实标记 (1 or 0)	为正例的概率
1	1	0.95
2	0	0.88
3	1	0.85
4	1	0.72
5	0	0.56

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{TN + FP}$$

第二回合：

以95%为阈值，则预测为正例的数量为1，预测为反例的数量为4。

真实情况	预测结果	
	正例	反例
正例	1 (TP)	2 (FN)
反例	0 (FP)	2 (TN)

$$TPR = 1/3, \quad FPR = 0$$

ROC曲线

样本序号	样本真实标记 (1 or 0)	为正例的概率
1	1	0.95
2	0	0.88
3	1	0.85
4	1	0.72
5	0	0.56

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{TN + FP}$$

第三回合：

以88%为阈值，则预测为正例的数量为2，预测为反例的数量为3。

真实情况	预测结果	
	正例	反例
正例	1 (TP)	2 (FN)
反例	1 (FP)	1 (TN)

$$TPR = 1/3, \quad FPR = 1/2$$

ROC曲线

样本序号	样本真实标记 (1 or 0)	为正例的概率
1	1	0.95
2	0	0.88
3	1	0.85
4	1	0.72
5	0	0.56

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{TN + FP}$$

第四回合：

以85%为阈值，则预测为正例的数量为3，预测为反例的数量为2。

真实情况	预测结果	
	正例	反例
正例	2 (TP)	1 (FN)
反例	1 (FP)	1 (TN)

$$TPR = 2/3, \quad FPR = 1/2$$

ROC曲线

样本序号	样本真实标记 (1 or 0)	为正例的概率
1	1	0.95
2	0	0.88
3	1	0.85
4	1	0.72
5	0	0.56

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{TN + FP}$$

第五回合：

以72%为阈值，则预测为正例的数量为4，预测为反例的数量为1。

真实情况	预测结果	
	正例	反例
正例	3 (TP)	0 (FN)
反例	1 (FP)	1 (TN)

$$TPR = 1, \quad FPR = 1/2$$

ROC曲线

样本序号	样本真实标记 (1 or 0)	为正例的概率
1	1	0.95
2	0	0.88
3	1	0.85
4	1	0.72
5	0	0.56

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{TN + FP}$$


第六回合：

以56%为阈值，则预测为正例的数量为5，预测为反例的数量为0。

真实情况	预测结果	
	正例	反例
正例	3 (TP)	0 (FN)
反例	2 (FP)	0 (TN)

$$TPR = 1, \quad FPR = 1$$

ROC曲线



ROC曲线

ROC曲线的绘制过程为 “按此顺序逐个把样本作为正例进行预测”。

□如果该案例真实情况为正例


则 TP 加 1，则 $TPR' = \frac{TP+1}{TP+FN} = TPR + \frac{1}{\text{真实正例总数}}$ ，

□如果该案例真实情况为反例

则 FP 加 1，则 $FPR' = \frac{FP+1}{TN+FP} = FPR + \frac{1}{\text{真实反例总数}}$ ，

ROC曲线

TPR



FPR


□ 若案例真实情况为**正例**,
则为“平行于y轴的直线”,
即下图“**橙线**”

□ 若案例真实情况为**反例**,
则为“平行于x轴的直线”,
即下图“**绿线**”

性能度量

□ ROC曲线与AUC

与P-R曲线类似，根据学习器的预测结果按**正例可能性大小**对**样本进行排序**，并逐个把样本作为正例进行预测绘制出的坐标曲线，其中，横坐标为FPR(假正率)，纵坐标为TPR（真正率）



□ 不同学习器ROC曲线比较

- 若一个学习器的ROC曲线能将另一个学习器完全**包住**，则前者性能优于后者
- 若两个学习器的ROC曲线发生**交叉**，则可通过曲线包围的面积(AUC)进行判断


性能度量

□ ROC曲线与AUC

● AUC

ROC曲线下的面积。假设ROC曲线由坐标为 $\{(x_1, y_1); \dots; (x_m, y_m)\}$ 的点按序连接而形成，则AUC可估算为

$$\text{AUC} = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i) \cdot (y_i + y_{i+1})$$



➤ AUC衡量了样本预测的**排序质量**，它与**排序误差**有紧密联系。

性能度量

□ ROC曲线与AUC

- ROC 与 AUC 和预测概率的数值大小无关；
- AUC衡量了样本预测的排序质量，它与排序误差有紧密联系；它表达的是“根据预测概率的排序”的好坏。


举例：

假设 $AUC = 0.7$ ，
表示我随便挑选一个正例，它被排在反例样本的前面的概率是0.7；

假设 $AUC = 0.5$ ，那这个模型就和随便猜测是一样的；

假设 $AUC = 1$ ，表示完美排序。

P-R曲线和ROC曲线



□ P-R曲线：

度量模型中所选取的**判断阈值**好坏，关注阈值选择对**查准率**和**召回率**的影响，适合评估不同阈值下的模型性能。

□ ROC曲线：

度量模型中**排序过程本身**的质量好坏，关注模型对正负样本的排序能力，不受具体阈值的影响。

性能度量

□ 代价敏感错误率

此前的性能度量并未考虑到不同类型的错误所导致的后果不同。为了权衡不同类型错误所造成的不同损失，可为错误赋予“非均等代价”

二分类代价矩阵

真实情况	预测结果	
	正例	反例
正例	0	c_1
反例	c_2	0

- 在非均等代价下，需要最小化总体代价，代价敏感错误率为：

$$E(f; D; cost) = \frac{1}{m} \left(\sum_{x_i \in D^+} \mathbb{I}(f(x_i) \neq y_i) \times c_1 + \sum_{x_i \in D^-} \mathbb{I}(f(x_i) \neq y_i) \times c_2 \right)$$

性能度量

□ 代价曲线：反应学习期的期望总体代价

代价曲线的横轴是取值为 $[0, 1]$ 的正例概率代价

$$P(+)\text{cost} = \frac{p \times c_1}{p \times c_1 + (1 - p) \times c_2}$$

纵轴是取值为 $[0, 1]$ 的归一化代价

归一化代价：

$$\text{cost}_{\text{norm}} = \frac{FNR \times p \times c_1 + FPR \times (1 - p) \times c_2}{p \times c_1 + (1 - p) \times c_2}$$


$FNR = 1 - TPR$, 假反率 FPR , 假正率

p : 样本为正例的概率

性能度量

□ 绘制代价曲线

- ROC曲线上每个点对应了代价曲线上的一条线段
- 设ROC曲线上点的坐标为 (TPR, FPR) ，则可相应计算出FNR
- 在代价平面上绘制一条从 $(0, \text{FPR})$ 到 $(1, \text{FNR})$ 的线段
- 线段下的面积即表示了该条件下的期望总体代价



大纲

- 经验误差与过拟合
- 评估方法
- 性能度量
- 偏差与方差

偏差与方差

□ 定义

- $\mathbf{x}$: 测试样本数据
- y : 样本 $\mathbf{x}$ 的真实标记
- y_D : 样本 $\mathbf{x}$ 在数据集中记录的标记（可能在收集数据时发生错误，导致 y_D 不完全等同于 y ）
- $\epsilon^2 = \mathbb{E}_D[(y_D - y)^2]$: 噪声
- $f(\mathbf{x}; D)$: 训练集 D 上学得模型 f 针对 $\mathbf{x}$ 的预测输出
- $\bar{f}(\mathbf{x}) = \mathbb{E}_D[f(\mathbf{x}; D)]$: 学习算法的期望预测
- $\text{var}(\mathbf{x}) = \mathbb{E}_D \left[\left(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}) \right)^2 \right]$: 样本数相同的不同训练集产生的方差
- $\text{bias}^2(\mathbf{x}) = \left(\bar{f}(\mathbf{x}) - y \right)^2$: 期望输出与真实标记的差距

偏差与方差

- 假设噪声的期望为0, 即 $\mathbb{E}_D[(y_D - y)] = 0$
- 则算法期望的泛化误差可以分解为

$$\begin{aligned} E(f; D) &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}) + \bar{f}(\mathbf{x}) - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y_D)^2 \right] \\ &\quad + \mathbb{E}_D \left[2(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))(\bar{f}(\mathbf{x}) - y_D) \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y + y - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y)^2 \right] + \mathbb{E}_D \left[(y - y_D)^2 \right] \\ &\quad + 2\mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y)(y - y_D) \right] \end{aligned}$$

偏差与方差

又由假设中噪声期望为0，可得

$$E(f; D) = \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + (\bar{f}(\mathbf{x}) - y)^2 + \mathbb{E}_D \left[(y_D - y)^2 \right]$$

于是： $E(f; D) = bias^2(\mathbf{x}) + var(\mathbf{x}) + \varepsilon^2$

也即泛化误差可分解为偏差、方差与噪声之和。


偏差与方差

- **偏差**度量了学习算法期望预测与真实结果的偏离程度；即刻画了学习算法本身的**拟合能力**。
- **方差**度量了同样大小训练集的变动所导致的学习性能的变化；即刻画了**数据扰动所造成的影响**。
- **噪声**表达了在当前任务上任何学习算法所能达到的期望泛化误差的下界；即刻画了**学习问题本身的难度**。

泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度所共同决定的。给定学习任务为了取得好的泛化性能，需要使**偏差小**（充分拟合数据）且**方差较小**（减少数据扰动产生的影响）。

偏差和方差


- **偏差 (Bias)** : 描述的是预测值 (估计值) 的期望与真实值之间的差距。偏差越大, 越偏离真实数据。
- **方差 (Variance)** : 描述的是预测值的变化范围, 离散程度, 也就是离其期望值的距离。方差越大, 数据的分布越分散。



偏差与方差


- 一般来说，**偏差**与**方差**是有**冲突**的，称为**偏差-方差困境**
如右图所示，假设我们能控制算法的训练程度：

- 当**训练不足**时，学习器拟合能力不强，训练数据的扰动不足以使学习器的拟合能力产生显著变化，此时**偏差**主导泛化错误率；
- 随着训练程度加深，学习器拟合能力逐渐增强，**方差**逐渐主导泛化错误率；
- 训练充分以后，学习器的拟合能力非常强，训练数据的轻微扰动都会导致学习器的显著变化，若训练数据自身非全局特性被学到则会发生过拟合。



第一章和第二章小结

□ 机器学习

1. 数据：数据集的划分  划分
方法 留出法、交叉验证法（留一法、
k折交叉验证法）、自助法

+

2. 训练模型（核心）： 监督学习、半监督学习，
无监督学习，强化学习

+

3. 模型评估： 性能度量：错误率和精度、
查准率P和查全率R（P-R曲线、F1、 F_β ）、
ROC和AUC

性能度量小结

□ 错误率

分类错误的样本在样本总数中的比例： $E = a/m$

错分样本数目
样本总数

离散任务（分类）

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) \neq y_i)$$

$\mathbb{I}(\cdot)$: 示性函数

连续任务（回归）

$p(\cdot)$: 概率密度函数

$$E(f; D) = \int_{\mathbf{x} \sim \mathcal{D}} \mathbb{I}(f(\mathbf{x}) \neq y) p(\mathbf{x}) d\mathbf{x}$$

$\mathcal{D}$: 数据分布

□ 精度

分类正确的样本在样本总数中的比例： $\text{acc}(f; D) = 1 - E(f; D)$

查准率&查全率

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

- **查准率**：强调模型预测的准确性，即**预测为正类**的样本中有多少是真正的正类。

$$P = \frac{TP}{TP + FP}$$

- **查全率**：强调模型的识别能力，即模型在**所有真实正类**中能够正确识别多少。

$$R = \frac{TP}{TP + FN}$$

性能度量小结

□ 二分类结果混淆矩阵

真实情况	预测结果	
	正例 (P)	反例 (N)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

真实的正例总数量: **$TP+FN$**

真实的反例总数量: **$FP+TN$**

$$\text{查准率 } P = \frac{TP}{TP+FP}$$

$$\text{查全率 } R = \frac{TP}{TP+FN}$$

注: 预测为正例的数量: **$TP+FP$**

□ 多分类结果混淆矩阵要如何计算 ??

例子：三分类混淆矩阵

A-vs-rest		Actual		
		A	B	C
Predicted	A	TRUE A	FALSE A, Actually B	FALSE A, Actually C
	B	FALSE B, Actually A	TRUE B	FALSE B, Actually C
	C	FALSE C, Actually A	FALSE C, Actually B	TRUE C

B-vs-rest		Actual		
		A	B	C
Predicted	A	TRUE A	FALSE A, Actually B	FALSE A, Actually C
	B	FALSE B, Actually A	TRUE B	FALSE B, Actually C
	C	FALSE C, Actually A	FALSE C, Actually B	TRUE C

C-vs-rest		Actual		
		A	B	C
Predicted	A	TRUE A	FALSE A, Actually B	FALSE A, Actually C
	B	FALSE B, Actually A	TRUE B	FALSE B, Actually C
	C	FALSE C, Actually A	FALSE C, Actually B	TRUE C

True Positive
 False Negative
 False Positive
 True Negative

A-vs-rest:

$$TP_A = \text{TRUE A}$$

$$FN_A = \text{FALSE B, Actually A} + \text{FALSE C, Actually A}$$

$$FP_A = \text{FALSE A, Actually B} + \text{FALSE A, Actually C}$$

$$TN_A = \text{TRUE B} + \text{FALSE B, Actually C} + \text{TRUE C} + \text{FALSE C, Actually B}$$

$$Precision_A = \frac{TP_A}{TP_A + FP_A}$$

$$Recall_A = \frac{TP_A}{TP_A + FN_A}$$

$$Precision_B = \frac{TP_B}{TP_B + FP_B}$$

$$Recall_B = \frac{TP_B}{TP_B + FN_B}$$

$$Precision_C = \frac{TP_C}{TP_C + FP_C}$$

$$Recall_C = \frac{TP_C}{TP_C + FN_C}$$

例子：三分类混淆矩阵

A-vs-rest		Actual		
		A	B	C
Predicted	A	TRUE A	FALSE A, Actually B	FALSE A, Actually C
	B	FALSE B, Actually A	TRUE B	FALSE B, Actually C
	C	FALSE C, Actually A	FALSE C, Actually B	TRUE C

B-vs-rest		Actual		
		A	B	C
Predicted	A	TRUE A	FALSE A, Actually B	FALSE A, Actually C
	B	FALSE B, Actually A	TRUE B	FALSE B, Actually C
	C	FALSE C, Actually A	FALSE C, Actually B	TRUE C

C-vs-rest		Actual		
		A	B	C
Predicted	A	TRUE A	FALSE A, Actually B	FALSE A, Actually C
	B	FALSE B, Actually A	TRUE B	FALSE B, Actually C
	C	FALSE C, Actually A	FALSE C, Actually B	TRUE C

True Positive
 False Negative
 False Positive
 True Negative

A-vs-rest:

$$TP_A = \text{TRUE A}$$

$$FN_A = \text{FALSE B, Actually A} + \text{FALSE C, Actually A}$$

$$FP_A = \text{FALSE A, Actually B} + \text{FALSE A, Actually C}$$

$$TN_A = \text{TRUE B} + \text{FALSE B, Actually C} + \text{TRUE C} + \text{FALSE C, Actually B}$$

$$Sensitivity_A = \frac{TP_A}{TP_A + FN_A} \quad Specificity_A = \frac{TN_A}{TN_A + FP_A}$$

$$Sensitivity_B = \frac{TP_B}{TP_B + FN_B} \quad Specificity_B = \frac{TN_B}{TN_B + FP_B}$$

$$Sensitivity_C = \frac{TP_C}{TP_C + FN_C} \quad Specificity_C = \frac{TN_C}{TN_C + FP_C}$$

例子：三分类混淆矩阵

$$Precision_A = \frac{TP_A}{TP_A + FP_A}$$

$$Recall_A = \frac{TP_A}{TP_A + FN_A}$$

$$Precision_B = \frac{TP_B}{TP_B + FP_B}$$

$$Recall_B = \frac{TP_B}{TP_B + FN_B}$$

$$Precision_C = \frac{TP_C}{TP_C + FP_C}$$

$$Recall_C = \frac{TP_C}{TP_C + FN_C}$$


$$Precision_{micro} = \frac{N_A}{N} \cdot Precision_A + \frac{N_B}{N} \cdot Precision_B + \frac{N_C}{N} \cdot Precision_C$$

$$Recall_{micro} = \frac{N_A}{N} \cdot Recall_A + \frac{N_B}{N} \cdot Recall_B + \frac{N_C}{N} \cdot Recall_C$$

性能度量小结

● 平衡点

P-R曲线上“查准率=查全率”时的取值，平衡点越高大，学习器性能越好（A优于B）



P-R曲线与平衡点示意图

性能度量小结

● $F1$ 度量

比平衡点更为常用的度量方式

$$F1 = \frac{2 \times P \times R}{P + R}$$

● F_β 度量

当对查全率、查准率有侧重点时使用的更为一般的度量方式

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

- 当 $\beta = 1$ 时，标准F1度量
- 当 $\beta < 1$ 时，偏重查准率(商品推荐系统)
- 当 $\beta > 1$ 时，偏重查全率(逃犯信息检索)

经验误差与过拟合

□ 误差

学习器**预测输出**与样本的**真实输出**之间的差异

➤ 训练误差 / 经验误差

学习器在**训练数据集**上的误差

➤ 泛化误差

学习器在**新样本数据**上的误差



新样本数据往往是**未知**的


学习器的训练方向：降低经验误差

但经验误差也并非越低越好

性能度量

□ P-R曲线

根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，从而得到查准率-查全率曲线



P-R曲线与平衡点示意图

查准率&查全率

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

- **查准率**：强调模型预测的准确性，即预测为正类的样本中有多少是真正的正类。

$$P = \frac{TP}{TP + FP}$$

- **查全率**：强调模型的识别能力，即模型在所有真实正类中能够正确识别多少。

$$R = \frac{TP}{TP + FN}$$

查准率&查全率

真实情况	预测结果	
	正例 (positive)	反例 (Negative)
正例	TP (真正率)	FN (假反率)
反例	FP (假正率)	TN (真反率)

- **查准率**：强调模型预测的准确性，即预测为正类的样本中有多少是真正的正类。

$$P = \frac{TP}{TP + FP}$$

- **查全率**：强调模型的识别能力，即模型在所有真实正类中能够正确识别多少。

$$R = \frac{TP}{TP + FN}$$