



第三章：线性模型

基本形式



模型可以视作对数据的拟合函数




不同的模型适应着不同的数据类型

基本形式

□ 线性模型

通过对数据样本属性的线性组合来进行预测的函数



➤ 当样本 $\mathbf{x} = (x_1; x_2; \dots; x_d) \in R^d$ 具有 d 个属性时, 线性函数

$$f(\mathbf{x}) = w_1 x_1 + w_2 x_2 + \dots + w_d x_d + b$$

向量形式



$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中, $\mathbf{w} = (w_1; \dots; w_d) \in R^d$, b 是确定线性模型的参数

基本形式

● 线性模型优势

- 形式简单、易于建模
- 参数 w 直观的表达了各属性在预测中的重要性，具有很好的解释性

- 假设训练出的挑好瓜的线性模型如下

$$f_{\text{好瓜}}(\mathbf{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

- 其中，根蒂系数最大，为0.5，表明在挑瓜的过程中，根蒂因素最为重要，敲声次之，而色泽最末

- 是许多功能强大的非线性模型基础

目录

□ 线性回归

- 最小二乘法

□ 二分类任务

- 对数几率回归
- 线性判别分析

□ 多分类任务

- 一对一
- 一对其余
- 多对多

□ 类别不平衡问题

线性回归

□ 线性回归

尽可能准确预测实值输出标记的线性模型，输出标记都是连续值

➤ 给定数据集 $D = \{(\mathbf{x}_1, y_1); \dots; (\mathbf{x}_m, y_m)\}$

- $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \in R^d$: 第 i 个数据样本
- $y_i \in R$: 第 i 个样本 $\mathbf{x}_i$ 的真实标记
- $f(\mathbf{x}_i)$: 学习器模型对数据 $\mathbf{x}_i$ 的预测结果



线性回归目标

如何确定合适的参数 $\mathbf{w} = (w_1; \dots; w_d) \in R^d, b$ ，使得线性回归模型的输出 $f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b$ 能尽可能的拟合 $\mathbf{x}_i$ 的真实标记 y_i ?

线性回归

□ 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$

其中 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$, $y_i \in \mathbb{R}$

□ 线性回归 (linear regression) 目的

- 学得一个线性模型以尽可能准确地预测实值输出标记

□ 离散属性处理

- 有“序”关系
 - 连续化为连续值
- 无“序”关系
 - 有k个属性值, 则转换为k维向量

线性回归

□ 单一属性的线性回归

$d = 1$ ，即样本数据只有一个属性



线性回归目标

如何确定合适的参数 $w, b \in R$ ，使得线性回归模型的输出 $f(x_i) = wx_i + b$ 能尽可能的拟合 x_i 的真实标记 y_i ?

➤ 参数估计：最小二乘法（最小化均方误差）

$$\begin{aligned}(w^*, b^*) &= \operatorname{argmin}_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \operatorname{argmin}_{(w, b)} \sum_{i=1}^m (wx_i + b - y_i)^2\end{aligned}$$

线性回归

□ 单一属性的线性回归

$d = 1$ ，即样本数据只有一个属性

令 $E_{(w,b)}$ 表示所有样本到由 (w, b) 确定的直线的距离之和

$$E_{(w,b)} = \sum_{i=1}^m (wx_i + b - y_i)^2$$

最小化 $E_{(w,b)}$  分别对 w, b 进行求导

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left(\sum_{i=1}^m (wx_i + b - y_i) x_i \right) = 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right) = 0$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left(\sum_{i=1}^m (wx_i + b - y_i) \right) = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right) = 0$$

线性回归

- 得到闭式 (closed-form) 解

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left(\sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

其中 $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

多元线性回归

□ 给定数据集

$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \quad y_i \in \mathbb{R}$$

□ 多元线性回归目标

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b \quad \text{使得} \quad f(\mathbf{x}_i) \simeq y_i, i = 1, \dots, m,$$

线性回归

□ 多元属性的线性回归

$d > 1$, 即样本数据有多个属性



线性回归目标

如何确定合适的参数 $\mathbf{w} = (w_1; \dots; w_d) \in R^d$, b , 使得线性回归模型的输出 $f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b$ 能尽可能的拟合 $\mathbf{x}_i$ 的真实标记 y_i ?

➤ 参数估计: 最小二乘法 (最小化均方误差)

$$\begin{aligned} (\mathbf{w}^*, b^*) &= \operatorname{argmin}_{(\mathbf{w}, b)} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2 \\ &= \operatorname{argmin}_{(\mathbf{w}, b)} \sum_{i=1}^m (\mathbf{w}^T \mathbf{x}_i + b - y_i)^2 \end{aligned}$$

线性回归

- 方便起见, 将参数 $\mathbf{w}, b$ 整合为一个向量 $\hat{\mathbf{w}} = (\mathbf{w}; b) \in R^{d+1}$, 并令 $\hat{\mathbf{x}}_i = (\mathbf{x}_i; 1) \in R^{d+1}$
- 数据集可以整合为矩阵 $\mathbf{X} \in R^{m \times (d+1)}$

The diagram illustrates the process of integrating data into a matrix $\mathbf{X}$ and deriving the loss function for linear regression. It shows how the matrix $\mathbf{X}$ is constructed from individual data points $\mathbf{x}_i$ and a bias term b , and how this leads to the calculation of the mean squared error (MSE) loss.

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

Diagram illustrating the integration of data into matrix $\mathbf{X}$ and the derivation of the loss function:

The matrix $\mathbf{X}$ is shown as a collection of rows, each representing a data point $\mathbf{x}_i$ augmented with a bias term 1. The matrix is partitioned into two parts: the feature matrix (indicated by a red dashed box) and the bias vector (indicated by a blue circle).

The function $f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b$ is shown, which is equivalent to $\hat{\mathbf{x}}_i^T \hat{\mathbf{w}}$ (where $\hat{\mathbf{x}}_i$ is the augmented feature vector and $\hat{\mathbf{w}}$ is the augmented parameter vector).

The loss function is defined as the sum of squared residuals:

$$\sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$$

This can be written in matrix form as:

$$= (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})^T (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})$$

where $\mathbf{y} = (y_1; y_2; \cdots; y_m)$ is the target vector.

线性回归

- 最小二乘法（最小化均方误差）

$$\hat{\mathbf{w}}^* = \arg \min_{\hat{\mathbf{w}}} (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})^T (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})$$

令 $E_{\hat{\mathbf{w}}} = (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})^T (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})$ ，对 $\hat{\mathbf{w}}$ 求导得到

$$\frac{\partial E_{\hat{\mathbf{w}}}}{\partial \hat{\mathbf{w}}} = 2\mathbf{X}^T(\mathbf{X}\hat{\mathbf{w}} - \mathbf{y})$$

令导数为零可得 $\hat{\mathbf{w}}$ 最优解的闭式解

多元线性回归 – 满秩讨论

- 当 $\mathbf{X}^T \mathbf{X}$ 是满秩矩阵或正定矩阵时，则

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中， $(\mathbf{X}^T \mathbf{X})^{-1}$ 是 $\mathbf{X}^T \mathbf{X}$ 的逆矩阵，线性回归模型

$$\begin{aligned} f(\mathbf{x}_i) &= \mathbf{w}^T \mathbf{x}_i + b \\ &= \hat{\mathbf{x}}_i^T \hat{\mathbf{w}} \end{aligned}$$

可表示为：

$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

多元线性回归 – 满秩讨论

□ $\mathbf{X}^T \mathbf{X}$ 是满秩矩阵或正定矩阵，则

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中 $(\mathbf{X}^T \mathbf{X})^{-1}$ 是 $\mathbf{X}^T \mathbf{X}$ 的逆矩阵，线性回归模型为

$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$


□ $\mathbf{X}^T \mathbf{X}$ 不是满秩矩阵

- 根据归纳偏好选择解（参见1.4节）
- 引入正则化（参加6.4节，11.4节）


对数线性回归

□ 对数线性回归

当输出标记在指数尺度上变化时，可以用输出标记的对数作为模型的线性逼近



$$y = \exp(\mathbf{w}^T \mathbf{x} + b)$$



$$\ln(y) = \mathbf{w}^T \mathbf{x} + b$$

线性回归 - 广义线性模型

- 一般形式 $y = g^{-1}(\boldsymbol{w}^T \boldsymbol{x} + b)$
- 将线性回归的结果映射到非线性空间
- $g(\cdot)$ 称为联系函数 (link function)
 - 单调可微函数
- 对数线性回归是 $g(\cdot) = \ln(\cdot)$ 时广义线性模型的特例。

目录

□ 线性回归

- 最小二乘法

□ 二分类任务

- 对数几率回归
- 线性判别分析

□ 多分类任务

- 一对一
- 一对其余
- 多对多

□ 类别不平衡问题

二分类任务

□ 预测值与输出标记

模型预测值: $z = f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$


二分类任务
的输出标记: $y \in \{0, 1\}$

□ 二分类任务

寻找合适的模型 $g^{-1}(\cdot)$ ，将分类标记与线性回归模型输出联系起来，使得输出结果 $z = f(\mathbf{x})$ 能尽可能准确的预测标记 $y \in \{0, 1\}$ ，即: $y = g^{-1}(z)$ 。

二分类任务

- 理想二分类模型——单位阶跃函数



$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

- 其中， $z = \mathbf{w}^T \mathbf{x} + b$ 是线性回归模型预测的实值
- 当 $z > 0$ 时， $y = 1$ ，判断为正例
- 当 $z < 0$ 时， $y = 0$ ，判断为负例

二分类任务


□ 单位阶跃函数缺点

- 不连续

□ 替代函数——对数几率函数 (**logistic function**)

- 单调可微、任意阶可导

$$y = \frac{1}{1 + e^{-z}}$$



单位阶跃函数与对数几率函数的比较

对数几率回归 ?

对数线性回归: $\ln(y) = \mathbf{w}^T \mathbf{x} + b$

□ 运用对数几率函数

$$y = \frac{1}{1 + e^{-z}} \rightarrow y = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

$$1 + e^{-(\mathbf{w}^T \mathbf{x} + b)} = \frac{1}{y}$$

$$e^{-(\mathbf{w}^T \mathbf{x} + b)} = \frac{1 - y}{y}$$

$$e^{(\mathbf{w}^T \mathbf{x} + b)} = \frac{y}{1 - y} \rightarrow \mathbf{w}^T \mathbf{x} + b = \ln \frac{y}{1 - y}$$

$$z = \mathbf{w}^T \mathbf{x} + b$$

对数几率回归

$$\text{对数线性回归: } \ln(y) = \mathbf{w}^T \mathbf{x} + b$$

□ 运用对数几率函数

y 表示样本 $\mathbf{x}$ 作为正例的可能性，则

$1 - y$ 表示样本 $\mathbf{x}$ 作为反例的可能性



$\frac{y}{1-y}$ 则称为**几率**，表示样本作为正例的相对可能性



$\ln \frac{y}{1-y}$ 则称为**对数几率** (log odds, 或 logit)



$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b$$

表示用**线性回归**模型的预测结果去逼近**真实标记的对数几率**。

对数几率回归

□ 对数几率回归（ **logistic regression**, 逻辑回归 ）：

$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b$$

注明：对数几率回归模型实际上是一种分类学习方法。

□ 对数几率回归优点

- 无需事先假设数据分布
- 可得到“类别”的近似概率预测
- 可直接应用现有数值优化算法求取最优解

对数几率回归

□ 对数几率回归（ **logistic regression**, 逻辑回归 ）：

$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b$$

注明：对数几率回归模型实际上是一种分类学习方法。

问题：如何求解该优化问题？也就是如何根据训练数据确定该模型的参数 **w** 和 **b** ？？

□ 对数几率回归（逻辑斯特函数）

Graph of the sigmoid function $p(z) = \frac{1}{1 + e^{-z}}$. The function maps any real-valued number into the range (0, 1). The graph shows the curve approaching 1 as z increases and approaching 0 as z decreases. The point $(0, 0.5)$ is marked on the curve. Red arrows indicate the piecewise definition of the function's output y based on the input z :

$$y = \begin{cases} 1 & z > 0 \\ 0.5 & z = 0 \\ 0 & z < 0 \end{cases}$$

$$\frac{\exp(\mathbf{w}^T \mathbf{x} + b)}{1 + \exp(\mathbf{w}^T \mathbf{x} + b)}$$

$$p(z) = \frac{1}{1 + \exp(-z)} = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x} - b)}$$

等价

对数几率回归

□ 对数几率回归（**logistic regression**, 逻辑回归）的求解：

假设输出 $p(z)$ 可以视作正例（即 $y = 1$ ）的概率

$$p(z) = \frac{1}{1 + \exp(-z)} = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x} - b)} = \frac{\exp(\mathbf{w}^T \mathbf{x} + b)}{1 + \exp(\mathbf{w}^T \mathbf{x} + b)}$$

$$1 - p(z) = 1 - \frac{\exp(\mathbf{w}^T \mathbf{x} + b)}{1 + \exp(\mathbf{w}^T \mathbf{x} + b)} = \frac{1}{1 + \exp(\mathbf{w}^T \mathbf{x} + b)}$$

二分类任务

$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b$$

□ 对数几率

$$\ln \frac{p(y = 1 \mid \mathbf{x})}{p(y = 0 \mid \mathbf{x})} = \mathbf{w}^T \mathbf{x} + b$$

显然有

$$p(y = 1 \mid \mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

$$p(y = 0 \mid \mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

二分类任务：极大似然法

- 根据输出 $p(z)$ 的定义

$$p(z_i) = \frac{\exp(\mathbf{w}^T \mathbf{x}_i + b)}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)}$$

样本预测为正例(即 $y_i = 1$)的概率

$$1 - p(z_i) = \frac{1}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)}$$

样本预测为反例(即 $y_i = 0$)的概率

似然函数



$$\prod_{i=1}^m (p(z_i))^{y_i} (1 - p(z_i))^{(1-y_i)}$$

二分类任务：极大似然法

- 根据输出 $p(z)$ 的定义

$$p(z_i) = \frac{\exp(\mathbf{w}^T \mathbf{x}_i + b)}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)} \quad 1 - p(z_i) = \frac{1}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)}$$

似然函数

样本预测为正例(即 $y_i = 1$)的概率

样本预测为反例(即 $y_i = 0$)的概率

$$\prod_{i=1}^m (p(z_i))^{y_i} (1 - p(z_i))^{(1-y_i)}$$

当样本为正例时， $1 - y_i = 0$ ，所以只有左半部分的预测概率有效，
由于左半部分是正确预测的概率，我们希望这样的概率越大越好

二分类任务：极大似然法

- 根据输出 $p(z)$ 的定义

$$p(z_i) = \frac{\exp(\mathbf{w}^T \mathbf{x}_i + b)}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)} \quad 1 - p(z_i) = \frac{1}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)}$$

似然函数

样本预测为正例(即 $y_i = 1$)的概率

样本预测为反例(即 $y_i = 0$)的概率

$$\prod_{i=1}^m (p(z_i))^{y_i} (1 - p(z_i))^{(1-y_i)}$$

当样本为反例时, $y_i = 0$, 所以只有右半部分的预测概率有效, 由于右半部分是正确预测的概率, 我们希望这样的概率越大越好

二分类任务：极大似然法

- 极大似然估计

$$\prod_{i=1}^m (p(z_i))^{y_i} (1 - p(z_i))^{(1-y_i)}$$



对其取对数，对数似然函数

$$L(\mathbf{w}, b) = \sum_{i=1}^m y_i \ln(p(z_i)) + (1 - y_i) \ln(1 - p(z_i))$$



合并同类项

$$L(\mathbf{w}, b) = \sum_{i=1}^m y_i \ln\left(\frac{p(z_i)}{1 - p(z_i)}\right) + \ln(1 - p(z_i))$$

由定义知 $\ln \frac{p(z)}{1-p(z)} = \mathbf{w}^T \mathbf{x} + b$



$$1 - p(z_i) = \frac{1}{1 + \exp(\mathbf{w}^T \mathbf{x}_i + b)}$$

$$L(\mathbf{w}, b) = \sum_{i=1}^m y_i (\mathbf{w}^T \mathbf{x} + b) - \ln(1 + \exp(\mathbf{w}^T \mathbf{x}_i + b))$$

二分类任务：极大似然法

□ 极大似然法 (**maximum likelihood**)

给定数据集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$,

- 最大化样本属于其真实标记的概率

- 最大化对数似然函数

$$\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i | \mathbf{x}_i; \mathbf{w}, b).$$

- 最大化对数似然函数（二分类）

$$p(y_i | \mathbf{x}_i; \mathbf{w}, b) = y_i p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) + (1 - y_i) p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})$$

二分类任务：极大似然法

- 极大似然估计



$$\begin{aligned}\mathbf{w}^*, b^* &= \arg \max_{\mathbf{w}, b} L(\mathbf{w}, b) \\ &= \sum_{i=1}^m y_i (\mathbf{w}^T \mathbf{x}_i + b) - \ln \left(1 + \exp(\mathbf{w}^T \mathbf{x}_i + b) \right)\end{aligned}$$

- 函数是高阶可导连续凸函数
- 可以采用梯度下降法/牛顿法等方法进行求解

优化计算方法：梯度下降法


基本思路：计算损失函数关于参数的梯度，并沿着梯度的负方向更新参数，使其逐步收敛到最优解（局部或全局最小值）

$$\begin{aligned} \mathbf{W}^l &= \mathbf{W}^l - \eta \frac{\partial L(\hat{\mathbf{y}}_i, \mathbf{y}_i)}{\partial \mathbf{W}^l} \\ \mathbf{b}^l &= \mathbf{b}^l - \eta \frac{\partial L(\hat{\mathbf{y}}_i, \mathbf{y}_i)}{\partial \mathbf{b}^l} \end{aligned}$$



优化计算方法：梯度下降法

局部最优解和全局最优解



线形回归 vs 逻辑回归

	区别	损失函数
线性回归	应用：回归问题 目的：找出最优拟合 输出是一个连续值	$L = \frac{1}{2m} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$
逻辑回归 (分类)	应用：分类问题 目的：找决策边界 输出是类别标识，如0, 1	极大似然法（课本，二分类任务）： $L = \sum_{i=1}^m -y_i(f(\mathbf{x}_i)) + \ln(1 + \exp(f(\mathbf{x}_i)))$ 交叉熵损失值（补充，二分类任务） (Cross-Entropy Loss)： $L = \sum_{i=1}^m -[y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$

y_i 表示样本*i*的真实值，正类为1，负类为0； p_i 表示样本*i*预测为正类的概率，取值范围0—1。

损失函数：交叉熵损失

● 信息熵

是度量样本集合纯度最常用的一种指标，表明随机变量不确定性的度量，假定当前样本集合 D 中第 k 类样本所占的比例为 p_k ， $k = 1, 2, \dots, |Y|$ ，则集合 D 的信息熵为

$$\text{Ent}(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

$\text{Ent}(D)$ 的值越小，则 D 的纯度越高。

● 交叉熵损失函数（多分类任务）：

$$L = \sum_{c=1}^n \sum_{i=1}^m -y_{ic} \log(p_{ic})$$

n 表示类别的数量，例如三分类任务时 $n = 3$ ；

y_{ic} 表示样本 i 的真实值，如真实类别为 c 类为1，否则为0；

p_{ic} 表示样本 i 预测为 c 类的概率，取值范围0—1。


二分类任务

□ 线性判别分析LDA

寻找直线 $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ ，使得当给定的训练样例集投影到直线上时满足

- 同类样本的投影点尽可能接近
- 异类样本的投影点尽可能远离

分类新样本时，可将新样本数据投影到直线上，再根据投影点位置确定新样本的类别



二分类任务 - 线性判别分析

□ LDA的思想

- 欲使同类样例的投影点尽可能接近，可以让同类样例投影点的协方差尽可能小
- 欲使异类样例的投影点尽可能远离，可以让类中心之间的距离尽可能大

□ 一些变量

- 第 i 类示例的集合 X_i
- 第 i 类示例的均值向量 μ_i
- 第 i 类示例的协方差矩阵 Σ_i
- 两类样本的中心在直线上的投影: $w^T \mu_0$ 和 $w^T \mu_1$
- 两类样本的协方差: $w^T \Sigma_0 w$ 和 $w^T \Sigma_1 w$

二分类任务

➤ 给定数据集 $D = \{(\mathbf{x}_1, y_1); \dots; (\mathbf{x}_m, y_m)\}$, $y_i \in \{0, 1\}$, 并令

- X_k : 第 $k \in \{0, 1\}$ 类样本的数据集合 (正/负样本数据集合)

- $\boldsymbol{\mu}_k = \frac{1}{|X_k|} \sum_{\mathbf{x} \in X_k} \mathbf{x}$: 第 k 类样本的均值向量

- $\boldsymbol{\Sigma}_k = \sum_{\mathbf{x} \in X_k} (\mathbf{x} - \boldsymbol{\mu}_k)(\mathbf{x} - \boldsymbol{\mu}_k)^T$: 第 k 类样本的协方差矩阵

- 同类样本的投影点尽可能接近



同类样本投影点的协方差 $\mathbf{w}^T \boldsymbol{\Sigma}_0 \mathbf{w} + \mathbf{w}^T \boldsymbol{\Sigma}_1 \mathbf{w}$ 尽可能小

- 异类样本的投影点尽可能远离



异同类样本投影点的中点 $\|\mathbf{w}^T \boldsymbol{\mu}_0 - \mathbf{w}^T \boldsymbol{\mu}_1\|^2$ 尽可能大

二分类任务 - 线性判别分析

□ 最大化目标

$$J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w}$$
$$= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w}$$

□ 类内散度矩阵

$$S_w = \Sigma_0 + \Sigma_1$$
$$= \sum_{x \in X_0} (x - \mu_0) (x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1) (x - \mu_1)^T$$

□ 类间散度矩阵

$$S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$$

二分类任务

- 最大化目标

$$J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} = \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w}$$

类间散度矩阵

$$S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$$

类内散度矩阵

$$S_w = \Sigma_0 + \Sigma_1$$

$$J = \frac{w^T S_b w}{w^T S_w w}$$

即最大化 S_b 、 S_w 的广义瑞利商

若 w 是问题的解，则对于任意常数 α ， αw 也是问题的解

解与 w 的长度无关，只与其方向有关

$$\begin{aligned} \min_w \quad & -w^T S_b w \\ \text{s.t.} \quad & w^T S_w w = 1 \end{aligned}$$

二分类任务

- 最大化目标

$$J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} = \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w}$$

类间散度矩阵

$$S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$$

类内散度矩阵

$$S_w = \Sigma_0 + \Sigma_1$$

$$J = \frac{w^T S_b w}{w^T S_w w}$$

即最大化 S_b 、 S_w 的广义瑞利商

若 w 是问题的解，则对于任意常数 α ， αw 也是问题的解

解与 w 的长度无关，只与其方向有关

$$\min_w -w^T S_b w$$

$$\text{s.t. } w^T S_w w = 1$$

如何求解该优化问题 ???

二分类任务 - 线性判别分析

- 广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

- 令 $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$, 最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$


- 运用拉格朗日乘子法

$$\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$

二分类任务

□ 拉格朗日乘子法

将有约束的最优化问题转化为无约束优化问题的方法




优化目标：寻找蓝色函数上距离原点最近的点，即 $f(x) = x_1^2 + x_2^2$ 尽可能小。

限制条件：最优解需在蓝色曲线上。则第一个与蓝色曲线相交的点即为解。

圆与函数曲线在极值点处相切

二分类任务

- 实际上坐标系上的每条曲线都可以视作一个函数的等高线



圆是 $f(\mathbf{x}) = x_1^2 + x_2^2$ 的等高线

蓝色曲线是 $g(\mathbf{x}) = x_1^2 x_2$ 其中一条等高线



根据函数梯度的定义


函数的梯度与其对应的等高线垂直

二分类任务

● 等式优化问题

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{sub.to} \quad & g(\mathbf{x}) = 0 \end{aligned}$$

- 对于约束曲面 $g(\mathbf{x}) = 0$ 上的任意点 $\mathbf{x}$ ，该点的梯度 $\nabla g(\mathbf{x}^*)$ 正交于约束曲面
- 在**最优点** $\mathbf{x}^*$ ，目标函数在该点的梯度 $\nabla f(\mathbf{x}^*)$ 正交于约束曲面



梯度 $\nabla f(\mathbf{x}^*)$ 与 $\nabla g(\mathbf{x}^*)$ 在同一个方向上

$$\nabla f(\mathbf{x}^*) + \lambda \nabla g(\mathbf{x}^*) = \mathbf{0}$$

二分类任务

- 优化问题

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \quad \xrightarrow{\quad} f(\mathbf{w}) \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \quad \xrightarrow{\quad} g(\mathbf{w}) = 0 \end{aligned}$$

$$\begin{aligned} \nabla f(\mathbf{w}) &= -\mathbf{S}_b \mathbf{w} - \mathbf{S}_b^T \mathbf{w} \\ &= -2\mathbf{S}_b \mathbf{w} \end{aligned}$$

$$\begin{aligned} \nabla g(\mathbf{w}) &= \mathbf{S}_w \mathbf{w} + \mathbf{S}_w^T \mathbf{w} \\ &= 2\mathbf{S}_w \mathbf{w} \end{aligned}$$

梯度 $\nabla f(\mathbf{w}^*)$ 与 $\nabla g(\mathbf{w}^*)$ 在同一个方向上

$$\nabla f(\mathbf{w}^*) + \lambda \nabla g(\mathbf{w}^*) = \mathbf{0}$$

$$\mathbf{S}_b \mathbf{w}^* = \lambda \mathbf{S}_w \mathbf{w}^*$$

$$\mathbf{S}_b \mathbf{w} = (\mu_0 - \mu_1) \boxed{(\mu_0 - \mu_1)^T \mathbf{w}} \quad \text{标量}$$

$$\text{不妨令 } \mathbf{S}_b \mathbf{w}^* = \lambda (\mu_0 - \mu_1)$$


$$\mathbf{w}^* = \mathbf{S}_w^{-1} (\mu_0 - \mu_1)$$

可用奇异值分解方法求解

$\mathbf{S}_b, \mathbf{S}_w$ 是对称矩阵


小结：线形模型（针对回归问题）

➤ 线形回归



$$f(x) = \mathbf{w}^T \mathbf{x} + b$$

➤ 对数线性回归：



$$y = \exp(\mathbf{w}^T \mathbf{x} + b)$$




$$\ln(y) = \mathbf{w}^T \mathbf{x} + b$$

小结：线形模型（针对分类问题）

➤ 对数几率回归（逻辑回归）：

寻找合适的模型 $f(\cdot)$ ，使得输出结果能尽可能准确的预测标记
 $y \in \{0, 1\}$

● 对数几率函数



对数几率回归的输出 $p(z)$ 可以视作正例（即 $y = 1$ ）的概率

小结：线形模型（针对分类问题）


□ 线性判别分析LDA

寻找直线 $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ ，使得当给定的训练样例集投影到直线上时满足

➤ 同类样本的投影点尽可能接近

➤ 异类样本的投影点尽可能远离

分类新样本时，可将新样本数据投影到直线上，再根据投影点位置确定新样本的类别



二分类任务 - 线性判别分析

- 广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

- 令 $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$, 最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

- 运用拉格朗日乘子法

$$\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$

小结：优化提要

□ 各任务下（回归、分类）各个模型的**优化目标**：

- 最小二乘法：最小化均方误差
- 对数几率回归：最大化样本分布似然，或交叉熵损失函数
- 线性判别分析：投影空间内最小（大）化类内（间）散度
(最大化广义瑞利商)

□ 参数 w 的**优化计算方法**：

- 最小二乘法：线性代数（求解导数为0的方程）
- 对数几率回归：凸优化梯度下降、牛顿法
- 线性判别分析：拉格朗日乘子法

目录

□ 线性回归

- 最小二乘法

□ 二分类任务

- 对数几率回归
- 线性判别分析

□ 多分类任务

- 一对一
- 一对其余
- 多对多

□ 类别不平衡问题

多分类学习

□ 多分类任务

寻找合适的模型 $f(\cdot)$ ，使得输出结果能尽可能准确的预测标记 $y \in \{1, 2, \dots, N\}$ # 数据有 N 个类别

● 基本思路

- 将多分类任务拆分为若干个二分类任务进行求解
- 测试时，集成二分类器结果来确定最终结果

● 经典方法

- 一对一 (One vs. One, OvO)
- 一对其余 (One vs. Rest, OvR)
- 多对多 (Many vs. Many, MvM)

多分类学习

□ 一对一：OvO

➤ 学习阶段

将 N 个类别两两配对，拆分为 $\frac{N(N-1)}{2}$ 个二类任务并分别进行学习

➤ 测试阶段

新样本提交给所有分类器进行预测，得到 $\frac{N(N-1)}{2}$ 个预测结果，其中，被预测最多的类别为最终结果

多分类学习

□ 一对其余：OvR


➤ 学习阶段

将所有类别中一类作为正类，其余视作负类，共拆分成 N 个分类器并进行学习


➤ 测试阶段

新样本提交给所有分类器进行预测，得到 N 个预测结果，按照置信度最大的类别得到最终的预测结果


多分类学习 - 两种策略比较



OvO




用于训练的
两类样例



OvR



用于训练的
两类样例



多分类学习

□ 两种策略的比较

预测性能取决于具体数据分布，多数情况下两者差不多

OvO	OvR
需要训练 $\frac{N(N-1)}{2}$ 个分类器，存储开销较大，测试时间相对较长	只需训练 N 个分类器，存储开销较小，测试时间相对较短
训练只需用到两个类别的样本，训练较快	训练时需用到所有类别全部的训练样本，训练较慢

多分类学习

□ 多对多 MvM

- 将若干类别作为正类，剩下的若干类别作为反类
- OvO与OvR都是MvM的特例
- MvM正反类的构造必须经过特殊的设计，不能随意选取

● 纠错输出码 (ECOC)

一种经典的MvM分类技术


编码：对 N 个类别做 M 次划分，每次划分将一部分类别划为正类，一部分划为反类

解码：测试样本交给 M 个分类器预测

构成 M 个二分类任务，各个类别长度为 M 的编码

距离最小的类别为最终类别

长度为 M 的编码预测



多分类学习 - 多对多

• 纠错输出码的示例

	f_1	f_2	f_3	f_4	f_5	海明距离	欧氏距离
$C_1 \rightarrow$	-1	+1	-1	+1	+1	3	$2\sqrt{3}$
$C_2 \rightarrow$	+1	-1	-1	+1	-1	4	4
$C_3 \rightarrow$	-1	+1	+1	-1	+1	1	2
$C_4 \rightarrow$	-1	-1	+1	+1	-1	2	$2\sqrt{2}$
测试示例 $\rightarrow$	-1	-1	+1	-1	+1		

(a) 二元 ECOC 码

[Dietterich and Bakiri, 1995]

	f_1	f_2	f_3	f_4	f_5	f_6	f_7	海明距离	欧氏距离
$C_1 \rightarrow$	-1	-1	+1	+1	-1	+1	+1	4	4
$C_2 \rightarrow$	-1	0	0	0	+1	-1	0	2	2
$C_3 \rightarrow$	+1	+1	-1	-1	-1	+1	-1	5	$2\sqrt{5}$
$C_4 \rightarrow$	-1	+1	0	+1	-1	0	+1	3	$\sqrt{10}$
测试示例 $\rightarrow$	-1	+1	+1	-1	+1	-1	+1		

(b) 三元 ECOC 码

[Allwein et al. 2000]

- ECOC编码对分类器错误有一定容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强

目录

□ 线性回归

- 最小二乘法

□ 二分类任务

- 对数几率回归
- 线性判别分析

□ 多分类任务

- 一对一
- 一对其余
- 多对多

□ 类别不平衡问题

类别不平衡问题

□ 类别不平衡问题

不同类别的训练样本数目相差很大（本节假设正类样本数目偏少）

- 输出 $y = \mathbf{w}^T \mathbf{x} + b$ 实际表达的是预测为正例的概率，通常当 $y > 0.5$ 时预测为正
- 几率 $\frac{y}{1-y}$ 反映了样本正例可能性与反例可能性之比

类别平衡时预测正例条件

$$\frac{y}{1-y} > 1$$



类别不平衡时预测正例条件

训练集中正例样本数目

$$\frac{y}{1-y} > \frac{m^+}{m^-}$$

训练集中负例样本数目

类别不平衡问题

● 再缩放

- 对训练集里的反类样例进行欠采样

去除一些反例使正反例数目接近

(EasyEnsemble [Liu et al.,2009])

- 对训练集里的正类样例进行过采样

增加一些正例使正反例数目接近

(SMOTE [Chawla et al.2002])

总结

□ 线性回归

- 最小二乘法（最小化均方误差）

□ 二分类任务

- 对数几率回归
 - 单位阶跃函数、对数几率函数、极大似然法
- 线性判别分析
 - 最大化广义瑞利商

□ 多分类学习

- 一对一
- 一对其余
- 多对多
 - 纠错输出码

□ 类别不平衡问题

- 基本策略：再缩放