
第四章：决策树


大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值（选讲）
- 多变量决策树（选讲）

基本流程

□ 决策树模型


是一种对样本实例进行分类的树形结构，由一个**根节点**，若干个**内部节点**与**叶节点**共同构成



➤ 从根节点到每个叶子节点的路径对应了一个判定测试序列

基本流程

□ 决策树模型



- 决策树的生成是一个递归过程
- 需要考虑 递归的结束条件 和 递归的执行过程

基本流程

□ 递归结束条件

□ 情况1:

当前结点所有样本都属于同一类别（已经分好了）

□ 情况2:

当前结点所有样本在所有属性上取值相同（属性都一样，没法区分）

□ 情况3:

当前结点包含的样本集为空，不能划分（没有样本了，自然无法再分了）

基本流程

□ 递归执行过程

□ 情况1:

不用处理，完美

□ 情况2:

标记为叶节点，类别设定为所含样本最多的类别

□ 情况3:

标记为叶节点，类别设定为其父节点所含样本最多的类别

基本流程

Algorithm 1 决策树学习基本算法

输入:

- 训练集 $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}$;
- 属性集 $A = \{a_1, \dots, a_d\}$.

过程: 函数 $\text{TreeGenerate}(D, A)$

```
1: 生成结点 node;  
2: if  $D$  中样本全属于同一类别  $C$  then  
3:   将 node 标记为  $C$  类叶结点; return  
4: end if  
5: if  $A = \emptyset$  OR  $D$  中样本在  $A$  上取值相同 then  
6:   将 node 标记叶结点, 其类别标记为  $D$  中样本数最多的类; return  
7: end if  
8: 从  $A$  中选择最优划分属性  $a_*$ ;  
9: for  $a_*$  的每一个值  $a_*^v$  do  
10:   为 node 生成每一个分枝; 令  $D_v$  表示  $D$  中在  $a_*$  上取值为  $a_*^v$  的样本子集;  
11:   if  $D_v$  为空 then  
12:     将分枝结点标记为叶结点, 其类别标记为  $D$  中样本最多的类; return  
13:   else  
14:     以  $\text{TreeGenerate}(D_v, A - \{a_*\})$  为分枝结点  
15:   end if  
16: end for
```

输出: 以 node 为根结点的一棵决策树

(1) 当前结点包含的
样本全部属于同一类别

(2) 当前属性集为空,
或所有样本在所有属性上
取值相同

(3) 当前结点包含的
样本集合为空

基本流程

- 决策树优势

- 很好的可读性
- 快速的分类速度

- 决策树模型构建关键

- 如何选择最优的划分属性，使得决策树的泛化能力强，对未见示例依然具有很强的预测能力？

提高分支节点的纯度



即希望决策树的分支结点所包含的样本尽可能属于同一类别

- 经典划分方法

- 信息增益
- 增益率
- 基尼指数

大纲

□ 基本流程

□ 划分选择

- 信息增益
- 增益率
- 基尼指数

□ 剪枝处理

□ 连续与缺失值（选讲）

□ 多变量决策树（选讲）

划分选择-信息增益

● 信息熵

是度量样本集合纯度最常用的一种指标，表明随机变量不确定性的度量，假定当前样本集合 D 中第 k 类样本所占的比例为 p_k ， $k = 1, 2, \dots, |\mathcal{Y}|$ ，则集合 D 的信息熵为

$$\text{Ent}(D) = - \sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

- $\text{Ent}(D)$ 的值越小，则 D 的纯度越高。
- 计算信息熵时约定：若 $p = 0$ ，则 $p \log_2 p = 0$
- $\text{Ent}(D)$ 的最小值为 0，最大值为 $\log_2 |\mathcal{Y}|$

划分选择-信息增益

➤ 示例

在17个训练样本的数据集 D 中，所有样本标签分为正、负两类， $|y| = 2$ 。

当正类样本占 $p_1 = \frac{8}{17}$ ，负类样本占 $p_2 = \frac{9}{17}$ 时，集合 D 的信息熵为

$$\text{Ent}(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.998$$

划分选择-信息增益

● 信息增益

假设离散属性 a 有 V 个不同的取值，用属性 a 对数据进行划分，则会产生 V 个分支结点，每个分支结点包含了在属性 a 上取值相同的样本子集 D^v ，样本数目为 $|D^v|$ 。则属性 a 对数据集 D 进行划分所获得的信息增益为

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

➤ 一般而言，信息增益越大，则按照属性 a 划分越能提升结点的纯度



最优的划分选择

信息增益最大的属性 a

划分选择-信息增益

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

● 信息增益

假设离散属性 a 有 V 个不同的取值 $\{a^1, a^2, \dots, a^V\}$,

若用属性 a 对数据集 D 进行划分, 则会产生 V 个分支结点,

其中, 第 v 个分支结点包含了 D 中所有在属性 a 上取值相同的样本子集 D^v ,

样本数目为 $|D^v|$, 我们可以计算出 D^v 的信息熵,

再考虑到不同的分支结点所包含的样本数不同,

给分支结点赋予权重: $|D^v| / |D|$,

即样本数越多的分支结点的影响越大,

于是, 可以计算出属性 a 对数据集 D 进行划分所获得的信息增益。



上面分为两个内容: 一个是“信息增益中权重的定义”,
一个是“信息增益的概念”。

划分选择-信息增益

- 示例：信息增益中权重的定义

权重的定义：

比如 西瓜有一个属性叫“色泽”，色泽有三种情况，“青绿”，“乌黑”，“浅白”

在本例中“离散属性 a ”指的就是“色泽”属性

在本例中“有 V 个可能取值 $\{a^1, a^2, \dots, a^V\}$ ”指的就是有三种情况， $V = 3$

属性取值 $a^1 = \text{“青绿”}$ ， $a^2 = \text{“乌黑”}$ ， $a^3 = \text{“浅白”}$

假设一共10个瓜，其中色泽为青绿、乌黑和浅白的分别有 2,3,5 个

则 $\frac{|D^v|}{|D|}$ 分别等于 $\frac{2}{10}$ ， $\frac{3}{10}$ ， $\frac{5}{10}$

划分选择-信息增益

- 示例：信息增益的概念

信息增益的概念：

$$Gain(D, a) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v)$$

信息增益 应该代表“信息熵的变化量”

所以 前面的 $Ent(D)$ 是“划分前的信息熵”

而 后面的 $\sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v)$ 应该是划分之后，各分支的信息熵乘以权重的总和

即“划分后的总信息熵”

$$\text{即 } \frac{2}{10} Ent(D(\text{青绿})) + \frac{3}{10} Ent(D(\text{乌黑})) + \frac{5}{10} Ent(D(\text{浅白}))$$

相减即可的“变化量”，即“信息增益”

划分选择-信息增益

● 示例：信息增益的概念

信息增益的意义：

信息增益越大，意味着使用 α 来划分所获得的“纯度提升”越大；
因此可以用信息增益作为选择决策树划分属性的判断依据。

- 熵越小，代表“混乱的程度”越小，代表样本纯度越高；
- 信息增益是“划分前的信息熵”减去“划分后的信息熵”；
- 当信息增益为正值，代表“熵变小，纯度变高”，才有划分的意义；
- 当信息增益为正值，且值越大，代表“熵变小的幅度更大，纯度变高的幅度更大；
- 我们的目的是分类，“纯度变高的幅度变大”说明分类效果好。

划分选择-信息增益



一个信息增益划分实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

数据集D中有17个训练样本，其中正类8个、负类9个，则集合D的信息熵

$$\text{Ent}(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k = - \frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.998$$

划分选择-信息增益

一个信息增益划分实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

数据集D中共计6个属性，假设依照属性 $a = \text{色泽}$ 对数据进行划分，则会产生青绿、乌黑、浅白3个分支，其中，青绿样本共计6个，3个好瓜，3个坏瓜，信息熵

$$\text{Ent}(D^1) = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = 1$$

划分选择-信息增益

一个信息增益划分实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

数据集D中共计6个属性，假设依照属性 $a = \text{色泽}$ 对数据进行划分，则会产生青绿、乌黑、浅白3个分支，其中，乌黑样本共计6个，4个好瓜，2个坏瓜，信息熵

$$\text{Ent}(D^2) = -\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} = 0.918$$

划分选择-信息增益

一个信息增益划分实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

数据集D中共计6个属性，假设依照属性 $a = \text{色泽}$ 对数据进行划分，则会产生青绿、乌黑、浅白3个分支，其中，浅白样本共计5个，1个好瓜，4个坏瓜，信息熵

$$\text{Ent}(D^3) = -\frac{1}{5} \log_2 \frac{1}{5} - \frac{4}{5} \log_2 \frac{4}{5} = 0.722$$

划分选择-信息增益

➤ 一个信息增益划分实例

数据集 D 根据色泽划分的信息增益

$$\begin{aligned}\text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - \frac{6}{17} \times 1 - \frac{6}{17} \times 0.918 - \frac{5}{17} \times 0.722 = 0.109\end{aligned}$$

类似的，计算其它属性划分的信息增益

$$\text{Gain}(D, \text{根蒂}) = 0.143$$

$$\text{Gain}(D, \text{纹理}) = 0.381$$

$$\text{Gain}(D, \text{触感}) = 0.006$$

$$\text{Gain}(D, \text{敲声}) = 0.141$$

$$\text{Gain}(D, \text{脐部}) = 0.289$$

最大信息增益，被选择为划分属性

划分选择-信息增益

➤ 一个信息增益划分实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

➤ 清晰样本 9个

➤ 稍糊样本 5个

➤ 模糊样本 3个

划分选择-信息增益

➤ 一个信息增益划分实例

根结点基于属性“**纹理**”的划分结果




重复以上步骤，继续计算结点内样本子集基于**不同属性**（排除纹理）划分的**信息增益**

划分选择-信息增益

➤ 一个信息增益划分实例

数据集D基于信息增益最终生成的决策树



划分选择-信息增益

- 存在问题

信息增益偏好可取值数目较多的属性

- 示例

假设依照属性 b 对样本进行划分，每个样本都对应着不同的属性值，则相应的信息增益为

$$\begin{aligned}\text{Gain}(D, b) &= \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - 17 \times \frac{1}{17} \times \left(\frac{1}{1} \log_2 \frac{1}{1} \right) = 0.998\end{aligned}$$

分支结点的纯度已经达到最大，不具备泛化能力

划分选择-增益率

● 增益率

假设离散属性 a 有 V 个不同的取值，用属性 a 对数据进行划分，则会产生 V 个分支结点，每个分支结点包含了在属性 a 上取值相同的样本子集 D^v ，样本数目为 $|D^v|$ 。则属性 a 对数据集 D 进行划分所获得的增益率为

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

➤ 其中，固有值 $\text{IV}(a)$ 为

$$\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

➤ 当属性 a 的取值越多，即 V 越大，则 $\text{IV}(a)$ 的取值通常越大

划分选择-增益率

一个求固有值IV(a)实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

假设依照属性 $a = \text{触感}$ 对数据集 D 进行划分，则会产生硬滑、软粘($V = 2$)个分支，其中，硬滑样本共计12个，软粘样本共计5个，则固有值

$$IV(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|} = - \frac{12}{17} \log_2 \frac{12}{17} - \frac{5}{17} \log_2 \frac{5}{17} = 0.874$$

划分选择-增益率

- 存在问题

增益率偏好可取值数目较少的属性

- 启发式划分方法

先从候选划分属性中找出信息增益高于平均水平的属性，再从中选取增益率最高的属性对结点数据集进行划分

划分选择-基尼指数

- 基尼值

假定当前样本集合 D 中第 k 类样本所占的比例为 p_k , $k = 1, 2, \dots, |Y|$, 则集合 D 的基尼值为

$$\text{Gini}(D) = - \sum_{k=1}^{|Y|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|Y|} p_k^2$$

$\text{Gini}(D)$ 反映了从数据集 D 中随机抽取两个样本, 其类别标记不一致的概率

$\text{Gini}(D)$ 越小, 则数据集 D 的纯度越高。

划分选择-基尼指数

- 基尼指数

属性 a 的基尼指数为

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

选择使得划分后的基尼指数最小的属性作为最优划分属性。

划分选择

基尼值： $Gini(D) = 1 - \sum_{k=1}^{|y|} p_k^2$

一个求基尼值实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

假设依照属性 $a = \text{触感}$ 对数据集 D 进行划分，则会产生 **硬滑**、**软粘** ($V = 2$) 个分支，其中，**硬滑** 样本共计 12 个（6 好 6 坏），**软粘** 样本共计 5 个（2 好 3 坏），类别 $|y| = 2$ ，则 **触感** 为 **硬滑** 的 **基尼值**：

$$Gini(\text{触感}|\text{硬滑}) = 1 - \left(\frac{6}{12}\right)^2 - \left(\frac{6}{12}\right)^2 = 0.5$$

划分选择

基尼值： $Gini(D) = 1 - \sum_{k=1}^{|y|} p_k^2$

一个求基尼值实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

假设依照属性 $a = \text{触感}$ 对数据集 D 进行划分，则会产生 **硬滑**、**软粘** ($V = 2$) 个分支，其中，**硬滑** 样本共计 12 个（6 好 6 坏），**软粘** 样本共计 5 个（2 好 3 坏），类别 $|y| = 2$ ，则 **触感** 为 **软粘** 的 **基尼值**：

$$Gini(\text{触感}|\text{软粘}) = 1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2 = 0.48$$

划分选择

$$\text{基尼指数: } \text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$



一个求基尼值实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

假设依照属性 $a = \text{触感}$ 对数据集 D 进行划分, 则会产生硬滑、软粘($V = 2$)个分支, 其中, 硬滑样本共计12个 (6好6坏), 软粘样本共计5个 (2好3坏), 类别 $|y| = 2$, 则属性 $a = \text{触感}$ 的基尼指数:

$$\text{Gini_index}(D, \text{触感}) = \frac{12}{17} \times 0.5 + \frac{5}{17} \times 0.48 = 0.494$$

$$\text{Gini_index}(D, \text{触感}) = \frac{12}{17} \times 0.5 + \frac{5}{17} \times 0.48 = 0.494$$

$$\text{Gini_index}(D, \text{色泽}) = \frac{4}{10} \left(1 - \left(\frac{2}{4} \right)^2 - \left(\frac{2}{4} \right)^2 \right) + \frac{2}{10} \left(1 - \left(\frac{2}{2} \right)^2 - \left(\frac{0}{2} \right)^2 \right) + \frac{4}{10} \left(1 - \left(\frac{3}{4} \right)^2 - \left(\frac{1}{4} \right)^2 \right) = \frac{4}{10} * \frac{1}{2} + 0 + \frac{4}{10} * \frac{6}{16} = \frac{7}{20} = 0.35$$

$$\text{Gini_index}(D, \text{根蒂}) = \frac{4}{10} \left(1 - \left(\frac{3}{4} \right)^2 - \left(\frac{1}{4} \right)^2 \right) + \frac{3}{10} \left(1 - \left(\frac{2}{3} \right)^2 - \left(\frac{1}{3} \right)^2 \right) + \frac{3}{10} \left(1 - \left(\frac{0}{3} \right)^2 - \left(\frac{3}{3} \right)^2 \right) = \frac{4}{10} * \frac{6}{16} + \frac{3}{10} * \frac{4}{9} = \frac{17}{60} = 0.28$$

$$\text{Gini_index}(D, \text{纹理}) = \frac{6}{10} \left(1 - \left(\frac{5}{6} \right)^2 - \left(\frac{1}{6} \right)^2 \right) + \frac{2}{10} \left(1 - \left(\frac{0}{2} \right)^2 - \left(\frac{2}{2} \right)^2 \right) + \frac{2}{10} \left(1 - \left(\frac{0}{2} \right)^2 - \left(\frac{2}{2} \right)^2 \right) = \frac{6}{10} * \frac{10}{36} + 0 + 0 = \frac{1}{6} = 0.17$$



“纹理”具有最小基尼指数，被选择为划分属性

决策树：划分选择小结

□ 划分选择

➤ 信息增益：

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

最优的划分选择：信息增益最大的属性 a

➤ 信息增益率：

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

➤ 基尼指数：

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

选择使得划分后的基尼指数最小的属性作为最优划分属性。

决策树：划分选择小结

➤ 信息增益：

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

其中，信息熵公式： $\text{Ent}(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k$

最优的划分选择：信息增益最大的属性 a

➤ 基尼指数：

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

其中，基尼值公式： $\text{Gini}(D) = 1 - \sum_{k=1}^{|y|} p_k^2$

选择使得划分后的基尼指数最小的属性作为最优划分属性。

大纲

- 基本流程
- 划分选择
- 剪枝处理
 - 预剪枝
 - 后剪枝
- 连续与缺失值（选讲）
- 多变量决策树（选讲）

剪枝处理

□ 剪枝处理

是解决决策树算法中“**过拟合**”现象的主要手段

- 一定程度上，可以通过剪枝来避免因**决策分支过多**，以致于把训练集**自身的一些特点**当做所有数据都具有的一般性质而导致的**过拟合**

● 基本策略

- **预剪枝**：在决策树生成过程中**判断**是否需要进行划分
- **后剪枝**：在训练集完整训练完一棵决策树后，自底向上**判断**是否要将子树替换为对应结点

● 判断方法

利用验证集数据判断决策树的**泛化性能**（第二章）是否有所提升

剪枝处理

➤ 利用“留出法”将西瓜数据集划分为训练集与测试集

训练集

好瓜5个，坏瓜5个

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否


测试集

好瓜3个，坏瓜4个

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

剪枝处理

- 采用信息增益进行属性划分，训练集可以生成决策树



剪枝处理

□ 预剪枝

在生成决策树过程中，对每个结点在划分前先进行估计

- 若当前结点的划分不能带来决策树泛化性能提升，则停止划分并将当前结点记为叶结点，其类别标记为训练样本数最多的类别

➤ 结点-脐部

分别计算划分前（即直接将该结点作为叶结点）及划分后的验证集精度，判断是否需要划分

- 若划分后能提高验证集精度，则对结点进行划分，并对划分后的属性执行同样的判断
- 否则，不进行不划分

剪枝处理

训练集

测试集

好瓜5个，坏瓜5个
好瓜3个，坏瓜4个

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

➤ 结点-脐部



脐部

脐部结点标记为叶结点，类别标记为好瓜

- 若不划分，测试集正确率为 $\frac{3}{7} \times 100\% = 42.9\%$

剪枝处理

训练集

好瓜5个，坏瓜5个

稍陷

训练集中，好瓜2个，坏瓜2个，标记为好瓜

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

稍陷

训练集中，好瓜0个，坏瓜2个，标记为坏瓜


测试集

好瓜3个，坏瓜4个

凹陷

训练集中，好瓜3个，坏瓜1个，标记为好瓜

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否



剪枝处理

训练集

好瓜5个，坏瓜5个

稍凹

测试集中，判断正确1个，判断错误1个

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

平坦

测试集中，判断正确2个，判断错误0个


测试集

好瓜3个，坏瓜4个

凹陷

测试集中，判断正确2个，判断错误1个


编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否



• 若划分，测试集正确率为 $\frac{5}{7} \times 100\% = 71.4\%$

剪枝处理-预剪枝

➤ 一个预剪枝示例



最终得到的仅有一层划分的决策树

剪枝处理

- 预剪枝优缺点

- 优点

- 降低过拟合风险
- 显著减少训练时间和测试时间开销

- 缺点

- 欠拟合风险：
 - 有些分支虽然当前划分不能提升泛化性能，但在其基础上进行的后续划分却有可能显著提高模型的泛化性能。
 - 预剪枝禁止这些分支的展开，带来了欠拟合风险


剪枝处理

□ 后剪枝

- 先从训练集生成一棵完整的决策树，再自底向上地对非叶结点进行考察
- 若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升，则将该子树替换为叶结点

剪枝处理-后剪枝

➤ 一个后剪枝示例




完整决策树，该决策树的验证集精度为42.9%

剪枝处理-后剪枝

➤ 若将结点6替换为叶结点

- 根据落在其上的训练样本类别，其标记为“好瓜”
- 验证集精度提升至57.1%，决定剪枝




验证集精度
剪枝前: 42.9%
剪枝后: 57.1%
后剪枝决策: 剪枝

剪枝处理-后剪枝

➤ 若将结点6替换为叶结点

- 根据落在其上的训练样本类别，其标记为“好瓜”
- 验证集精度提升至57.1%，决定剪枝




将结点6替换为叶结点结果

剪枝处理-后剪枝

➤ 若将结点5替换为叶结点

- 根据落在其上的训练样本类别，其标记为“好瓜”
- 验证集精度仍为57.1%，可以不剪枝




验证集精度
剪枝前: 57.1 %
剪枝后: 57.1%
后剪枝决策: 不剪枝

剪枝处理

➤ 若将结点2替换为叶结点


- 根据落在其上的训练样本类别，其标记为“好瓜”
- 验证集精度提升至**71.4%**，决定剪枝



验证集精度
剪枝前: 57.1%
剪枝后: 71.4%
后剪枝决策: 剪枝


剪枝处理-后剪枝

- 对结点③和①，先后替换为叶结点，验证集精度均未提升，则分支得到保留



剪枝处理-后剪枝

➤ 最终基于后剪枝策略得到的决策树



剪枝处理

- 后剪枝优缺点

- 优势

- 后剪枝比预剪枝保留了更多的分支，**欠拟合风险小**，泛化性能往往优于预剪枝决策树

- 缺点

- **训练时间开销大**：后剪枝是在生成完全决策树之后进行的，需要自底向上对所有非叶结点逐一考察

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值（选讲）
- 多变量决策树（选讲）

连续与缺失值 - 连续值处理

□ 连续属性离散化(二分法)

- 第一步：假定连续属性 a 在样本集 D 上出现 n 个不同的取值，从小到大排列，记为 $a^1, a^2, \dots, a^n$ ，基于划分点 t ，可将 D 分为子集 D_t^- 和 D_t^+ ，其中 D_t^- 包含那些在属性 a 上取值不大于 t 的样本， D_t^+ 包含那些在属性 a 上取值大于 t 的样本。考虑包含 $n - 1$ 个元素的候选划分点集合：

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n - 1 \right\}$$

即把区间 $[a^i, a^{i+1})$ 的中位点， $\frac{a^i + a^{i+1}}{2}$ 作为候选划分点。

连续与缺失值 - 连续值处理

□ 连续属性离散化(二分法)

- 第二步：采用离散属性值方法，考察这些划分点，选取最优的划分点进行样本集合的划分：

$$\begin{aligned}\text{Gain}(D, a) &= \max_{t \in T_a} \text{Gain}(D, a, t) \\ &= \max_{t \in T_a} \text{Ent}(D) - \sum_{\lambda \in \{-, +\}} \frac{|D_t^\lambda|}{|D|} \text{Ent}(D_t^\lambda)\end{aligned}$$

其中 $\text{Gain}(D, a, t)$ 是样本集 D 基于划分点 t 二分后的信息增益，于是，就可选择使 $\text{Gain}(D, a, t)$ 最大化的划分点。

连续与缺失值 - 连续值处理

连续值处理实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

对属性“密度”，其候选划分点集合包含 16 个候选值：

$$T_{\text{密度}} = \{0.244, 0.294, 0.351, 0.381, 0.420, 0.459, 0.518, 0.574, 0.600, 0.621, 0.636, 0.648, 0.661, 0.681, 0.708, 0.746\}$$

可计算其信息增益为 0.262，对应划分点为 0.381

对属性“含糖量”进行同样处理

与离散属性不同，若当前结点划分属性为连续属性，该属性还可作为其后代结点的划分属性。

连续与缺失值 - 缺失值处理

- 不完整样本，即样本的属性值缺失
- 仅使用无缺失的样本进行学习？

对数据信息极大的浪费

- 使用有缺失值的样本，需要解决哪些问题？

Q1：如何在属性缺失的情况下进行划分属性选择？

Q2：给定划分属性（在已经完成上述Q1的计算的情况下），若样本在该属性上的值缺失，如何对样本进行划分？

连续与缺失值 - 缺失值处理

Q1: 如何在属性缺失的情况下进行划分属性选择?

□ 第一步: 计算无缺失子集 $\tilde{D}$ 的信息熵:

$$\text{Ent}(\tilde{D}) = - \sum_{k=1}^{|\mathcal{Y}|} \tilde{p}_k \log_2 \tilde{p}_k$$

□ 第二步: 计算无缺失子集 $\tilde{D}$ 上相应属性的信息增益 (“色泽”为例):

$$\text{Gain}(\tilde{D}, \text{色泽}) = \text{Ent}(\tilde{D}) - \sum_{v=1}^3 \tilde{r}_v \text{Ent}(\tilde{D}^v)$$

□ 第三步: 计算最终样本集 D 上属性“色泽”的信息增益:

$$\text{Gain}(D, a) = \rho \times \text{Gain}(\tilde{D}, a)$$

最终信息增益 = 无缺失的样本的信息增益 × 无缺失样本占总样本的比例

连续与缺失值 - 缺失值处理

□ $\tilde{D}$ 表示 D 中在属性 a 上没有缺失值的样本子集, $\tilde{D}^v$ 表示 $\tilde{D}$ 中在属性 a 上取值为 a^v 的样本子集, $\tilde{D}_k$ 表示 $\tilde{D}$ 中属于第 k 类的样本子集

为每个样本 $\mathbf{x}$ 赋予一个权重 w_x , 并定义:

- 无缺失值样本所占的比例

$$\rho = \frac{\sum_{x \in \tilde{D}} w_x}{\sum_{x \in D} w_x}$$

- 无缺失值样本中第 k 类所占比例

$$\tilde{p}_k = \frac{\sum_{x \in \tilde{D}_k} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \leq k \leq |\mathcal{Y}|)$$

- 无缺失值样本中在属性 a 上取值 a^v 的样本所占比例

$$\tilde{r}_v = \frac{\sum_{x \in \tilde{D}^v} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \leq v \leq V)$$

连续与缺失值 - 缺失值处理

缺失值处理实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

- 学习开始时，根结点包含样本集 D 中全部 17 个样例，各样例的权值均为 1；
- 以属性“色泽”为例，该属性上无缺失值的样例子集 $\tilde{D}$ 包含 14 个样例，那么 $\tilde{D}$ 的信息熵为：

$$\text{Ent}(\tilde{D}) = - \sum_{k=1}^2 \tilde{p}_k \log_2 \tilde{p}_k$$

$$= -\left(\frac{6}{14} \log_2 \frac{6}{14} + \frac{8}{14} \log_2 \frac{8}{14}\right) = 0.985$$

连续与缺失值 - 缺失值处理

□ 令 $\tilde{D}^1$, $\tilde{D}^2$, $\tilde{D}^3$ 分别表示在属性“色泽”上取值为“青绿”、“乌黑”以及“浅白”的样本子集, 有

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

$$\text{Ent}(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k$$

$$\text{Ent}(\tilde{D}^1) = - \left(\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4} \right) = 1.000$$

$$\text{Ent}(\tilde{D}^2) = - \left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6} \right) = 0.918$$

$$\text{Ent}(\tilde{D}^3) = - \left(\frac{0}{4} \log_2 \frac{0}{4} + \frac{4}{4} \log_2 \frac{4}{4} \right) = 0.000$$

连续与缺失值 - 缺失值处理

因此，样本子集 $\tilde{D}$ 上属性“色泽”的信息增益为

$$\begin{aligned}\text{Gain}(\tilde{D}, \text{色泽}) &= \text{Ent}(\tilde{D}) - \sum_{v=1}^3 \tilde{r}_v \text{Ent}(\tilde{D}^v) \\ &= 0.985 - \left(\frac{4}{14} \times 1.000 + \frac{6}{14} \times 0.918 + \frac{4}{14} \times 0.000 \right) \\ &= 0.306\end{aligned}$$

$$\text{其中, } \tilde{r}_v = \frac{\sum_{x \in \tilde{D}^v} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \leq v \leq V)$$

□ 于是，样本集 D 上属性“色泽”的信息增益为

$$\text{Gain}(D, \text{色泽}) = \rho \times \text{Gain}(\tilde{D}, \text{色泽}) = \frac{14}{17} \times 0.306 = 0.252$$

连续与缺失值 - 缺失值处理

□ 类似地可计算出所有属性在数据集上的信息增益

$$\text{Gain}(D, \text{色泽}) = 0.252$$

$$\text{Gain}(D, \text{根蒂}) = 0.171$$

$$\text{Gain}(D, \text{敲声}) = 0.145$$

$$\text{Gain}(D, \text{纹理}) = 0.424$$

$$\text{Gain}(D, \text{脐部}) = 0.289$$

$$\text{Gain}(D, \text{触感}) = 0.006$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

连续与缺失值 - 缺失值处理

Q2: 给定划分属性（在已经完成上述Q1的计算的情况下），若样本在该属性上的值缺失，如何对样本进行划分？

- 若样本 $\mathbf{x}$ 在划分属性 a 上的取值已知，则将 $\mathbf{x}$ 划入与其取值对应的子结点，且样本权值在子结点中保持为 w_x ；（正常划分）
- 若样本 $\mathbf{x}$ 在划分属性 a 上的取值未知，则将 $\mathbf{x}$ 同时划入所有子结点，且样本权值在与属性值 a^v 对应的子结点中调为 $\tilde{r}_v \cdot w_x$ 。
（直观来看，相当于让同一个样本以不同概率划入不同的子结点中）

连续与缺失值 - 缺失值处理

以“纹理”为例： $\text{Gain}(D, \text{纹理}) = 0.424$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

进入“纹理=清晰”分支

进入“纹理=稍糊”分支

进入“纹理=模糊”分支

样本权重在各子结点仍为1

在属性“纹理”上出现缺失值，样本 8 和 10 同时进入3个分支，调整 8 和 10 在

3个分支权值分别为：

清晰：7/15

稍糊：5/15



模糊：3/15

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值（选讲）
- 多变量决策树（选讲）


多变量决策树

□ 单变量决策树，其分类边界：轴平行。



多变量决策树

- 单变量决策树分类边界:轴平行
- 多变量决策树




- 非叶节点不再是仅对某个属性，而是对属性的线性组合




- 每个非叶结点是一个形如 $\sum_{i=1}^d w_i a_i = t$ 的线性分类器 w_i ，其中 a_i 是属性 w_i 的权值，和 可在该结点所含的样本集和属性集上学得。

多变量决策树

□ 多变量决策树




含糖率



决策树小结

□ 决策树模型



- 决策树的生成是一个递归过程
- 需要考虑 递归的结束条件 和 递归的执行过程

决策树小结

□ 划分选择

➤ 信息增益:

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

最优的划分选择: 信息增益最大的属性 a

➤ 信息增益率:

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

➤ 基尼指数:

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

选择使得划分后的基尼指数最小的属性作为最优划分属性。

决策树小结

➤ 信息增益:

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

其中，信息熵公式： $\text{Ent}(D) = - \sum_{k=1}^{|y|} p_k \log_2 p_k$

最优的划分选择：信息增益最大的属性 a

➤ 基尼指数:

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

其中，基尼值公式： $\text{Gini}(D) = 1 - \sum_{k=1}^{|y|} p_k^2$

选择使得划分后的基尼指数最小的属性作为最优划分属性。