
第七章：贝叶斯分类器

章节目录

- 贝叶斯决策论
- 极大似然估计
- 朴素贝叶斯分类器

例子

- ❑ **问题1**：假设天气预报下雨，我们需要决定出门时是否需要带伞。
- ❑ **问题2**：假设有一个用于诊断某种疾病（阳性）的测试，我们需要决定一个人是否患有这种疾病。
- ❑ **问题3**：假设某种疾病（称为疾病A）通常表现出发热和咳嗽在内的症状。目前有位病人既有发热也有咳嗽，医生需要确定该病人是否患有某种疾病。
- ❑ **贝叶斯分类器**：
贝叶斯分类器通过考虑先验概率和条件概率（似然性）来做出决策，以最小化总体误差。

贝叶斯决策论

□ 贝叶斯决策论 (Bayesian decision theory) 是在概率框架下实施决策的基本方法。

- 在分类问题情况下，在所有相关概率都已知的理想情形下，贝叶斯决策考虑如何基于这些概率和误判损失来选择最优的类别标记。

□ 朴素贝叶斯 (Naive Bayes) :

- 根据事件的先验知识描述事件的概率，对联合概率建模来获得目标概率值；

贝叶斯决策论

□ 贝叶斯决策论 (Bayesian decision theory) 是在概率框架下实施决策的基本方法。

- 在分类问题情况下, 在所有相关概率都已知的理想情形下, 贝叶斯决策考虑如何基于这些概率和误判损失来选择最优的类别标记。

□ 假设有 N 种可能的类别标记, 即 $y = \{c_1, c_2, \dots, c_N\}$, λ_{ij} 是将一个真实标记为 c_j 的样本误分类为 c_i 所产生的损失。基于后验概率 $P(c_i | \mathbf{x})$ 可获得将样本 $\mathbf{x}$ 分类为 c_i 所产生的期望损失 (expected loss), 即在样本上的“条件风险” (conditional risk)

$$R(c_i | \mathbf{x}) = \sum_{j=1}^N \lambda_{ij} P(c_j | \mathbf{x}) \quad (7.1)$$

□ 我们的任务是寻找一个模型 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 以最小化总体风险 (期望)

$$R(h) = \mathbf{E}_x [R(h(\mathbf{x}) | \mathbf{x})] \quad (7.2)$$

例子1

□ 问题：

一个学生需要根据天气预报决定是否带伞去学校，以下是损失函数：

- 如果下雨而学生没有带伞，损失为**10**（被淋湿）。
- 如果不下雨而学生带了伞，损失为**2**（携带伞的不便）。
- 其他所有情况的损失为**0**。

□ 后验概率 $P(c_i|x)$ ：

根据天气预报，我们估计以下概率：

- 如果预报下雨，实际下雨的概率是**0.8**，则实际不下雨的概率是**0.2**。
- 如果预报不下雨，实际不下雨的概率是**0.9**，则实际下雨的概率是**0.1**。

例子1

□ 决策计算:

假设今天的天气预报预测下雨。这个学生需要决定是否带伞

□ 答案:

(1) 如果学生带伞:

- 实际下雨的概率是0.8, 损失为0。
- 实际不下雨的概率是0.2, 损失为2。
- 期望损失 = $0.8 \times 0 + 0.2 \times 2 = 0 + 0.4 = 0.4$

最终决定带伞

(2) 如果学生不带伞:

- 实际下雨的概率是0.8, 损失为10。
- 实际不下雨的概率是0.2, 损失为0。
- 期望损失 = $0.8 \times 10 + 0.2 \times 0 = 8 + 0 = 8$

贝叶斯决策论

□ 显然，对每个样本 $\mathbf{x}$ ，若 h 能最小化条件风险 $R(h(\mathbf{x}) | \mathbf{x})$ ，则总体风险 $R(h)$ 也将被最小化。

□ 这就产生了**贝叶斯判定准则** (Bayes decision rule)：为最小化总体风险，只需在每个样本上选择那个**能使条件风险** $R(c | \mathbf{x})$ **最小的类别标记**，即

$$h^*(x) = \operatorname{argmin}_{c \in y} R(c | x) \quad (7.3)$$

- 此时， h^* 被称为**贝叶斯最优分类器**(Bayes optimal classifier)，与之对应的总体风险 $R(h^*)$ 称为**贝叶斯风险** (Bayes risk);
- $1 - R(h^*)$ 反映了分类所能达到的最好性能，即通过机器学习所能产生的模型精度的理论上限。

贝叶斯决策论

□ 具体来说，若目标是**最小化分类错误率**，则误判损失 λ_{ij} 可写为

$$\lambda_{i,j} \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise,} \end{cases} \quad (7.4)$$

□ 此时条件风险



$$R(c_i | \mathbf{x}) = \sum_{j=1}^N \lambda_{ij} P(c_j | \mathbf{x})$$

$$R(c | \mathbf{x}) = 1 - P(c | \mathbf{x}) \quad (7.5)$$

贝叶斯决策论

□ 此时条件风险

$$R(c \mid \mathbf{x}) = 1 - P(c \mid \mathbf{x}) \quad (7.5)$$



$$h^*(x) = \operatorname{argmin}_{c \in y} R(c \mid x)$$

□ 于是，最小化分类错误率的贝叶斯最优分类器为

$$h^*(x) = \operatorname{argmax}_{c \in y} P(c \mid x) \quad (7.6)$$

- 即对每个样本 $\mathbf{x}$ ，选择能使后验概率 $P(c \mid \mathbf{x})$ 最大的类别标记。

贝叶斯决策论

$$h^*(x) = \operatorname{argmax}_{c \in y} P(c \mid x) \quad (7.6)$$

- 不难看出，使用贝叶斯判定准则来最小化决策风险，首先要获得后验概率 $P(c \mid \mathbf{x})$ 。
- 然而，在现实中通常难以直接获得。机器学习所要实现的是基于有限的训练样本尽可能准确地估计出后验概率 $P(c \mid \mathbf{x})$ 。

贝叶斯决策论

□ 主要有两种策略：

- 判别式模型 (discriminative models)

- 给定 $\mathbf{x}$ ，通过直接建模 $P(c | \mathbf{x})$ ，来预测 c
- 决策树，BP神经网络，支持向量机

- 生成式模型 (generative models)

- 先对联合概率分布 $P(\mathbf{x}, c)$ 建模，再由此获得 $P(c | \mathbf{x})$
- 生成式模型考虑

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

贝叶斯决策论

□ 生成式模型

$$P(c \mid \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

贝叶斯决策论

□ 生成式模型

$$P(c \mid \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理, $P(c \mid \mathbf{x})$ 可写成

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})} \quad (7.8)$$

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

先验概率
样本空间中各类样本所占的
比例，可通过各类样本出现
的频率估计（大数定理）

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

先验概率

样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

对于所有类别，概率相同

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

类标记 C 相对于样本 $\mathbf{x}$ 的“类条件概率” (class-conditional probability), 或称“似然”。

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

对于所有类别，概率相同

贝叶斯决策论

□ 由公式

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

可知，估计 $P(c | \mathbf{x})$ 的问题就转换成了如何基于训练数据，来估计先验 $P(c)$ 和 $P(\mathbf{x} | c)$ 。

□ 先验概率 $P(c)$ ：当数据集包含充足的“独立同分布”样本时， $P(c)$ 可以通过各类样本出现的频率来进行估计。

□ 类条件概率 $P(\mathbf{x} | c)$ ：它涉及关于 $\mathbf{x}$ 所有属性的联合概率，直接

根据样本出现的频率来估计会遇到严重的困难。

例子 2

□ **问题：** 假设有一个用于诊断某种疾病（阳性）的测试，我们需要决定一个人是否患有这种疾病。

□ **贝叶斯分类器：**

贝叶斯分类器通过考虑先验概率和条件概率（似然性）来做出决策，以最小化总体误差。

例子 2

□ **问题：** 假设有一个用于诊断某种疾病（阳性）的测试，我们需要决定一个人是否患有这种疾病，也就是计算 $P(\text{生病} \mid \text{阳性})$ 。

□ 假设在一般人群中该疾病的患病率（先验概率）为0.01（1%）。有一个测试，其性能如下：

- 灵敏度（TP，真阳性率，即病人被正确诊断为阳性的概率）为95%。
- 特异性（TN，真阴性率，即健康人被正确诊断为阴性的概率）为90%。

例子 2

□ 问题：假设有一个用于诊断某种疾病（阳性）的测试，我们需要决定一个人是否患有这种疾病，也就是计算 $P(\text{生病} \mid \text{阳性})$ 。

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})}$$

C : 生病

$\mathbf{x}$: 阳性

例子 2

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})}$$

一般人群中该疾病的患病率（先验概率）为**0.01（1%）**。

- 灵敏度（TP，真阳性率，即病人被正确确诊为阳性的概率）为 **95%**。
- 特异性（TN，真阴性率，即健康人被正确诊断为阴性的概率）为 **90%**。

$$P(\text{生病})=0.01 \quad \rightarrow \quad P(\text{健康})=1- P(\text{生病})=1-0.01=0.99$$

$$P(\text{阳性} | \text{生病})=0.95$$

$$P(\text{阴性} | \text{健康})=0.9$$



$$P(\text{阳性} | \text{健康})=1- P(\text{阴性} | \text{健康}) =1- 0.9 =0.1$$

例子 2

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})}$$

□问题：假设有一个用于诊断某种疾病（阳性）的测试，我们需要决定一个人是否患有这种疾病，也就是计算 $P(\text{生病} \mid \text{阳性})$ 。

$$P(\text{生病} \mid \text{阳性}) = \frac{P(\text{阳性} \mid \text{生病}) \times P(\text{生病})}{P(\text{阳性})}$$

$$P(\text{生病}) = 0.01,$$

$$P(\text{阳性} \mid \text{生病}) = 0.95$$

$$\begin{aligned} P(\text{阳性}) &= P(\text{阳性} \mid \text{生病}) \times P(\text{生病}) + P(\text{阳性} \mid \text{健康}) \times P(\text{健康}) \\ &= 0.95 \times 0.01 + 0.1 \times 0.99 = 0.1085 \end{aligned}$$

$$P(\text{生病} \mid \text{阳性}) = \frac{0.95 \times 0.01}{0.1085} \approx 0.0876$$

贝叶斯决策论

□ 此时条件风险

$$R(c | \mathbf{x}) = 1 - P(c | \mathbf{x}) \quad (7.5)$$



$$h^*(x) = \operatorname{argmin}_{c \in y} R(c | x)$$

□ 于是，最小化分类错误率的贝叶斯最优分类器为

$$h^*(x) = \operatorname{argmax}_{c \in y} P(c | x) \quad (7.6)$$

- 即对每个样本 $\mathbf{x}$ ，选择能使后验概率 $P(c | \mathbf{x})$ 最大的类别标记。

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

类标记 C 相对于样本 $\mathbf{x}$ 的“类条件概率” (class-conditional probability), 或称“似然”。

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

对于所有类别，概率相同

参数估计的两个学派

□ 频率主义学派

- 认为参数虽然未知，但却是“客观存在”的“固定值”
- 可通过优化似然函数等准则来确定参数值
- 极大似然估计

□ 贝叶斯学派


- 认为参数是未观察到的随机变量，其本身也可“有分布”
(就是“非确定的”)
- 可假定参数服从一个先验分布
- 朴素贝叶斯分类器

章节目录

- 贝叶斯决策论
- 极大似然估计
- 朴素贝叶斯分类器

极大似然估计

- 估计类条件概率 $P(\mathbf{x} | c)$ 的常用策略：先假定其具有某种确定的概率分布形式，再基于训练样本对概率分布参数估计。



- 记关于类别 C 的类条件概率为 $P(\mathbf{x} | c)$,
 - 假设 $P(\mathbf{x} | c)$ 具有确定的形式并且被参数 θ_c 唯一确定，我们的任务就是利用训练集 D 估计参数 θ_c

极大似然估计

- 令 D_c 表示训练集中第 C 类样本的集合，假设这些样本是独立的，则参数 θ_c 对于数据集 D_c 的似然是

$$P(D_c | \theta_c) = \prod_{\mathbf{x} \in D_c} P(\mathbf{x} | \theta_c) \quad (7.9)$$

- 对 θ_c 进行极大似然估计，寻找能最大化似然 $P(D_c | \theta_c)$ 的参数值 $\hat{\theta}_c$ 。直观上看，极大似然估计是试图在 θ_c 所有可能的取值中，找到一个使数据出现的“可能性”最大值。

极大似然估计

- 令 D_c 表示训练集中第 C 类样本的组合集，假设这些样本是独立的，则参数 θ_c 对于数据集 D_c 的似然是

$$P(D_c | \theta_c) = \prod_{\mathbf{x} \in D_c} P(\mathbf{x} | \theta_c) \quad (7.9)$$

- 对 θ_c 进行极大似然估计，寻找能最大化似然 $P(D_c | \theta_c)$ 的参数值 $\hat{\theta}_c$ 。直观上看，极大似然估计是试图在 θ_c 所有可能的取值中，找到一个使数据出现的“可能性”最大值。

- 式 (7.9) 的连乘操作易造成下溢，通常使用对数似然(log-likelihood)

$$\begin{aligned} LL(\theta_c) &= \log P(D_c | \theta_c) \\ &= \sum_{\mathbf{x} \in D_c} \log P(\mathbf{x} | \theta_c) \end{aligned} \quad (7.10)$$

- 此时参数 θ_c 的极大似然估计 $\hat{\theta}_c$ 为 $\hat{\theta}_c = \operatorname{argmax}_{\theta_c} LL(\theta_c)$ (7.11)

极大似然估计

- 例如，在连续属性情形下，假设概率密度函数 $p(\mathbf{x} | c) \sim N(\boldsymbol{\mu}_c, \boldsymbol{\sigma}_c^2)$ ，则参数 $\boldsymbol{\mu}_c$ 和 $\boldsymbol{\sigma}_c^2$ 的极大似然估计为

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{|D_c|} \sum_{\mathbf{x} \in D_c} \mathbf{x} \quad (7.12)$$

$$\hat{\boldsymbol{\sigma}}_c^2 = \frac{1}{|D_c|} \sum_{\mathbf{x} \in D_c} (\mathbf{x} - \hat{\boldsymbol{\mu}}_c)(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)^T \quad (7.13)$$

- 也就是说，通过极大似然法得到的正态分布均值就是样本均值，方差就是 $(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)^T$ 的均值，这显然是一个符合直觉的结果。
- 需注意的是，这种参数化的方法虽能使类条件概率估计变得相对简单，但估计结果的准确性严重依赖于所假设的概率分布形式是否符合潜在的真实数据分布。

章节目录

- 贝叶斯决策论
- 极大似然估计
- 朴素贝叶斯分类器

朴素贝叶斯分类器

- 估计后验概率 $P(c | \mathbf{x})$ 主要困难：类条件概率 $P(\mathbf{x} | c)$ 是所有属性上的联合概率，难以从有限的训练样本估计获得。
- 朴素贝叶斯分类器(Naïve Bayes Classifier)采用了“属性条件独立性假设”(attribute conditional independence assumption)：每个属性独立地对分类结果发生影响。

朴素贝叶斯分类器

□ 基于属性条件独立性假设，贝叶斯最佳分类器

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})} \quad (7.8)$$

可重写为

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i \mid c) \quad (7.14)$$

- 其中 d 为属性数目， x_i 为 $\mathbf{x}$ 在第 i 个属性上的取值。

朴素贝叶斯分类器

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i \mid c) \quad (7.14)$$

由于对所有类别来说 $P(x)$ 相同，因此基于式 (7.6) 的贝叶斯判定准则有

$$h_{nb}(\mathbf{x}) = \operatorname{argmax}_{c \in y} P(c) \prod_{i=1}^d P(x_i \mid c) \quad (7.15)$$

- 这就是朴素贝叶斯分类器的表达式子

朴素贝叶斯分类器

□ 朴素贝叶斯分类器的训练器的训练过程就是基于训练集 D 估计类先验概率 $P(c)$ 并为每个属性估计条件概率 $P(x_i | c)$ 。

- 令 D_c 表示训练集 D 中第 c 类样本组合的集合，若有充足的独立同分布样本，则可容易地估计出类先验概率

$$P(c) = \frac{|D_c|}{D} \quad (7.16)$$

- 对离散属性而言，令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样本组成的集合，则条件概率 $P(x_i | c)$ 可估计为

$$P(x_i | c) = \frac{|D_{c,x_i}|}{D} \quad (7.17)$$

- 对连续属性而言，可考虑概率密度函数，假定 $p(x_i | c) \sim N(\mu_{c,i}, \sigma_{c,i}^2)$ ，其中 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 分别是第 c 类样本在第 i 个属性上取值的均值和方差，则有

$$P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right) \quad (7.18)$$

小结：贝叶斯决策论 & 朴素贝叶斯分类器

□ 贝叶斯决策论（Bayesian decision theory）是在概率框架下实施决策的基本方法。

- 在分类问题情况下，在所有相关概率都已知的理想情形下，贝叶斯决策考虑如何基于这些概率和误判损失来选择最优的类别标记。

□ 朴素贝叶斯（Naive Bayes）：

- 根据事件先验知识描述事件的概率，对联合概率建模来获得目标概率值；
- 采用“属性条件独立性假设”：每个属性独立地对分类结果发生影响。

小结：贝叶斯决策论

□ 贝叶斯最优分类器：
(最小化决策风险)

$$h^*(x) = \operatorname{argmin}_{c \in y} R(c | x)$$



$$R(c | \mathbf{x}) = 1 - P(c | \mathbf{x})$$

□ 优化目标：
(最大化后验概率)

$$h^*(x) = \operatorname{argmax}_{c \in y} P(c | x)$$

即,



$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})}$$

$P(x)$ ：对于所有类别都一样

小结：朴素贝叶斯分类器

□ 贝叶斯最优分类器：
(最小化决策风险)

$$h^*(x) = \operatorname{argmin}_{c \in y} R(c | x)$$



$$R(c | \mathbf{x}) = 1 - P(c | \mathbf{x})$$

□ 最优目标：
(最大化后验概率)

$$h^*(x) = \operatorname{argmax}_{c \in y} P(c | x)$$



$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i | c)$$

$P(x)$: 对于所有类别, 概率相同

□ 朴素贝叶斯分类器：

$$h_{nb}(\mathbf{x}) = \operatorname{argmax}_{c \in y} P(c) \prod_{i=1}^d P(x_i | c)$$

朴素贝叶斯分类器

□ 实例

利用西瓜数据集3.0 (p84) 训练一个朴素贝叶斯分类器，并对测试样本“测1”进行分类预测

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测 1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	?

朴素贝叶斯分类器

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

先验概率

$P(c = \text{好瓜}) = \frac{8}{17} \approx 0.471$

$P(c = \text{坏瓜}) = \frac{9}{17} \approx 0.529$

朴素贝叶斯分类器

测1: 色泽=青绿

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率

$$P_{\text{青绿}|\text{好瓜}} = \frac{3}{8} = 0.375$$

$$P_{\text{青绿}|\text{坏瓜}} = \frac{3}{9} \approx 0.333$$

朴素贝叶斯分类器

测1: 根蒂=蜷缩

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率

$$P_{\text{蜷缩}|\text{好瓜}} = \frac{5}{8} = 0.625$$

$$P_{\text{蜷缩}|\text{坏瓜}} = \frac{3}{9} \approx 0.333$$

朴素贝叶斯分类器

测1: 敲声=浊响

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率

$$P_{\text{浊响}|\text{好瓜}} = \frac{6}{8} = 0.750$$

$$P_{\text{浊响}|\text{坏瓜}} = \frac{4}{9} \approx 0.444$$

朴素贝叶斯分类器

测1: 纹理=清晰

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率

$$P_{\text{清晰}|\text{好瓜}} = \frac{7}{8} = 0.875$$

$$P_{\text{清晰}|\text{坏瓜}} = \frac{2}{9} \approx 0.222$$

朴素贝叶斯分类器

测1: 脐部=凹陷

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率

$$P_{\text{凹陷}|\text{好瓜}} = \frac{5}{8} = 0.625$$

$$P_{\text{凹陷}|\text{坏瓜}} = \frac{2}{9} \approx 0.222$$

朴素贝叶斯分类器

测1: 触感=硬滑

西瓜数据集3.0

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{D}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率

$$P_{\text{硬滑}|\text{好瓜}} = \frac{6}{8} = 0.750$$

$$P_{\text{硬滑}|\text{坏瓜}} = \frac{6}{9} \approx 0.667$$

朴素贝叶斯分类器

测1: 密度=0.697

西瓜数据集3.0

$$P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

均值 = 0.574, 方差 ≈ 0.129

均值 = 0.496, 方差 ≈ 0.195

属性估计条件概率 $P_{\text{密度}=0.697|\text{好瓜}} = \frac{1}{\sqrt{2\pi} \times 0.129} \exp\left(-\frac{(0.697 - 0.574)^2}{2 \times 0.129^2}\right) \approx 1.959$

朴素贝叶斯分类器

测1: 密度=0.697

西瓜数据集3.0

$$P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

均值 = 0.574, 方差 ≈ 0.129

均值 = 0.496, 方差 ≈ 0.195

属性估计条件概率 $P_{\text{密度}=0.697|\text{坏瓜}} = \frac{1}{\sqrt{2\pi} \times 0.129} \exp\left(-\frac{(0.697 - 0.496)^2}{2 \times 0.195^2}\right) \approx 1.203$

朴素贝叶斯分类器

测1: 含糖率=0.460

西瓜数据集3.0

$$P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.609	0.318	是
5	浅白	蜷缩	浊响	清晰	稍凹	软粘	0.403	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.481	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.437	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.243	0.099	否
13	青绿	稍蜷	沉闷	稍糊	稍凹	硬滑	0.657	0.161	否
14	浅白	稍蜷	沉闷	稍糊	稍凹	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

均值 = 0.279, 方差 ≈ 0.101

均值 = 0.154, 方差 ≈ 0.108

属性估计条件概率 $P_{\text{含糖率}=0.460|\text{好瓜}} = \frac{1}{\sqrt{2\pi} \times 0.101} \exp\left(-\frac{(0.460 - 0.279)^2}{2 \times 0.101^2}\right) \approx 0.788$

朴素贝叶斯分类器

测1: 含糖率=0.460

西瓜数据集3.0

$$P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.609	0.318	是
5	浅白	蜷缩	浊响	清晰	稍凹	软粘	0.403	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.481	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.437	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.243	0.099	否
13	青绿	稍蜷	沉闷	稍糊	稍凹	硬滑	0.657	0.161	否
14	浅白	稍蜷	沉闷	稍糊	稍凹	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

均值 = 0.279, 方差 ≈ 0.101

均值 = 0.154, 方差 ≈ 0.108

属性估计条件概率 $P_{\text{含糖率}=0.460|\text{坏瓜}} = \frac{1}{\sqrt{2\pi} \times 0.108} \exp\left(-\frac{(0.460 - 0.154)^2}{2 \times 0.108^2}\right) \approx 0.066$

朴素贝叶斯分类器

- 朴素贝叶斯分类器

$$\begin{aligned} P(c = \text{好瓜} | x = \text{样本1}) \\ = P(c = \text{好瓜}) \times P_{\text{青绿}|\text{好瓜}} \times P_{\text{蜷缩}|\text{好瓜}} \times P_{\text{浊响}|\text{好瓜}} \times P_{\text{清晰}|\text{好瓜}} \\ \times P_{\text{凹陷}|\text{好瓜}} \times P_{\text{硬滑}|\text{好瓜}} \times P_{\text{密度}=0.697|\text{好瓜}} \times P_{\text{含糖}=0.460|\text{好瓜}} \approx 0.038 \end{aligned}$$

$$\begin{aligned} P(c = \text{坏瓜} | x = \text{样本1}) \\ = P(c = \text{坏瓜}) \times P_{\text{青绿}|\text{坏瓜}} \times P_{\text{蜷缩}|\text{坏瓜}} \times P_{\text{浊响}|\text{坏瓜}} \times P_{\text{清晰}|\text{坏瓜}} \\ \times P_{\text{凹陷}|\text{坏瓜}} \times P_{\text{硬滑}|\text{坏瓜}} \times P_{\text{密度}=0.697|\text{坏瓜}} \times P_{\text{含糖}=0.460|\text{坏瓜}} \approx 6.80 \times 10^{-5} \end{aligned}$$



测试样本1为好瓜

拉普拉斯修正

□ 存在问题

- 若训练集中不存在某个属性值，则直接计算属性的条件概率会出现问题
- 例

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测2	x	x	清脆	x	x	x	x	x	?

$$P_{\text{清脆}|\text{好瓜}} = \frac{0}{8} = 0$$

$$P_{\text{清脆}|\text{坏瓜}} = \frac{2}{8} = 0.250$$



只要敲声 = 清脆，样本则为坏瓜

显然并不合理

拉普拉斯修正

□ 拉普拉斯修正 (Laplacian correction)

避免其他属性携带信息被训练集中未出现的属性值抹去

- 令 N 表示训练集 D 中可能的类别数, N_i 表示第 i 个属性可能的取值数, 则先验概率和属性的条件概率可修正为

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N} \quad (7.19)$$

$$\hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D| + N_i} \quad (7.20)$$

朴素贝叶斯分类器

西瓜数据集3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

先验概率

$$P(c = \text{好瓜}) = \frac{8 + 1}{17 + 2} \approx 0.474$$

$$P(c = \text{坏瓜}) = \frac{9 + 1}{17 + 2} \approx 0.526$$

朴素贝叶斯分类器

西瓜数据集3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

属性估计条件概率 $P_{\text{青绿}|\text{好瓜}} = \frac{3 + 1}{8 + 3} = 0.364$ $P_{\text{青绿}|\text{坏瓜}} = \frac{3 + 1}{9 + 3} \approx 0.333$

拉普拉斯修正

□ 存在问题

- 若训练集中不存在某个属性值，则直接计算属性的条件概率会出现问题
- 例

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测2	x	x	清脆	x	x	x	x	x	?

$$P_{\text{清脆}|\text{好瓜}} = \frac{0}{8} = 0$$

$$P_{\text{清脆}|\text{坏瓜}} = \frac{2}{8} = 0.250$$



拉普拉斯修正

$$P_{\text{清脆}|\text{好瓜}} = \frac{0 + 1}{8 + 3} = 0.091$$

$$P_{\text{清脆}|\text{坏瓜}} = \frac{2 + 1}{8 + 3} = 0.273$$

半朴素贝叶斯分类器

□ 朴素贝叶斯分类器(Naïve Bayes Classifier)

- 采用了“属性条件独立性假设”

□ 半朴素贝叶斯分类器(Semi-naïve Bayes Classifier)

- 基本想法：“适当考虑一部分属性间的相互依赖信息”
- “独依赖估计”(One-Dependent Estimator, ODE)
假设“每个属性在类别之外最多仅依赖于一个其他属性”
- 问题的关键就转化为“如何确定每个属性的父属性”，不同的做法产生不同的独依赖分类器